



Projet de Fin d'Études

Analyse Prédictive sur des Données Réelles

Parcours Data Analyst

Année universitaire 2024–2025

Réalisé par : Aritendry Ramahafeno
En collaboration avec : Bernardin RASOLONJANAHARY
Encadré par : Docteur Dimby

Table des matières

Remerciements	2
Résumé	3
Abstract	4
1 Introduction Générale	5
1.1 Contexte	5
1.2 Problématique	5
1.3 Objectifs	5
1.4 Démarche méthodologique	5
1.5 Structure du document	6
1.6 Exploration des données	6
1.6.1 Chargement du jeu de données	6
1.6.2 Aperçu des données	6
1.6.3 Traitement des valeurs manquantes	6
1.6.4 Détection de doublons	7
1.6.5 Étude des valeurs aberrantes	7
1.6.6 Étude des corrélations	7
1.6.7 Conclusion de l'exploration	7
2 Visualisation des Données	8
2.1 Introduction	8
2.2 Analyse univariée	9
2.3 Analyse bivariée	15
2.4 Conclusion	19
2.5 Présentation du Dataset	19
3 Modélisation	24
3.1 Évaluation des modèles	24
3.2 Résultats comparatifs	24
3.3 Courbes d'apprentissage	24
3.4 Discussion	29
4 Déploiement	30
4.1 Test interactif du modèle	30
4.2 Chargement du modèle	30
4.3 Illustration du script	30

5 Conclusion	31
---------------------	-----------

Remerciements

Avant toute chose, nous rendons grâce à Dieu Tout-Puissant, source de toute sagesse et de toute force, pour nous avoir accompagnés tout au long de ce parcours académique, et pour nous avoir accordé la santé, la persévérance et le courage nécessaires à la réalisation de ce projet.

Nous tenons à exprimer notre profonde reconnaissance à Docteur Dimby pour son encadrement rigoureux, ses conseils éclairés et sa disponibilité, qui ont grandement contribué à l'aboutissement de ce travail.

Nos remerciements s'adressent également à l'ensemble des enseignants du département Informatique de l'Institut National Supérieur d'Informatique, pour les connaissances transmises et leur engagement envers notre formation.

Nous remercions également nos camarades de promotion pour leur esprit de collaboration, leur entraide et les moments partagés durant cette année universitaire.

Enfin, nous exprimons toute notre gratitude à nos familles respectives pour leur soutien moral, leurs encouragements constants et leur confiance en nous.

Résumé

Ce projet de fin d'année porte sur la prédiction du taux de réussite au concours d'entrée à l'université. À partir d'un jeu de données comportant plusieurs variables telles que le score GRE, le score TOEFL, la moyenne générale (CGPA), et d'autres facteurs académiques, nous avons nettoyé et analysé les données afin de construire un modèle prédictif performant. Nous avons utilisé un classifieur Random Forest pour estimer la probabilité d'admission d'un candidat. Les résultats obtenus montrent une bonne précision, démontrant que les variables sélectionnées sont pertinentes pour prédire l'admission. Ce travail ouvre la voie à des outils d'aide à la décision pour les futurs candidats et les établissements d'enseignement supérieur.

Abstract

This final year project focuses on predicting the success rate of candidates in university entrance exams. Using a dataset containing variables such as GRE scores, TOEFL scores, GPA, and other academic factors, we cleaned and analyzed the data to build an effective predictive model. A Random Forest classifier was used to estimate the probability of candidate admission. The obtained results show good accuracy, indicating that the selected variables are relevant for predicting admission. This work paves the way for decision support tools for future candidates and higher education institutions.

Chapitre 1

Introduction Générale

1.1 Contexte

L'accès à l'université est un enjeu majeur pour de nombreux étudiants, et les concours d'entrée constituent souvent une étape déterminante. Prédire le taux de réussite à ces concours permet non seulement d'aider les futurs candidats à mieux se préparer, mais aussi d'accompagner les établissements dans leurs processus de sélection.

1.2 Problématique

La prédiction du succès au concours d'entrée est un défi complexe qui repose sur l'analyse de plusieurs facteurs académiques et personnels. Les données disponibles sont souvent volumineuses, hétérogènes et bruitées, ce qui complique l'élaboration de modèles fiables. Il est donc nécessaire de développer des méthodes efficaces pour traiter ces données et produire des prédictions précises.

1.3 Objectifs

L'objectif principal de ce projet est de construire un modèle prédictif capable d'estimer la probabilité de réussite des candidats au concours d'entrée à l'université, à partir de données académiques telles que les scores aux tests standardisés (GRE, TOEFL), la moyenne générale et d'autres variables pertinentes.

1.4 Démarche méthodologique

Pour atteindre cet objectif, nous avons collecté plusieurs jeux de données, puis procédé à une sélection rigoureuse afin de retenir celui offrant la meilleure qualité et fiabilité. Les données ont été nettoyées, transformées et analysées exploratoirement. Ensuite, différents modèles d'apprentissage automatique ont été testés, évalués et comparés, pour finalement retenir le plus performant.

1.5 Structure du document

Ce rapport est organisé en plusieurs parties. La première partie présente l'étude et la préparation des données. La deuxième partie détaille la modélisation, les choix et évaluations des algorithmes. La troisième partie analyse les résultats obtenus. Enfin, la dernière partie propose des perspectives d'amélioration et de déploiement futur.

1.6 Exploration des données

1.6.1 Chargement du jeu de données

Le jeu de données a été chargé au format CSV à l'aide de la bibliothèque `pandas` :

```
import pandas as pd
df = pd.read_csv("admission_data.csv")
```

La commande `df.info()` a permis d'obtenir un aperçu des colonnes, de leurs types et du nombre de valeurs non nulles. On compte 9 colonnes et 550 lignes.

1.6.2 Aperçu des données

- Le jeu de données contient des variables quantitatives continues (*GRE Score*, *TOEFL Score*, *CGPA*, *Chance of Admit*) et discrètes (*University Rating*, *SOP*, *LOR*, *Research*).
- L'attribut *Chance of Admit* est la variable cible. Elle indique la probabilité d'admission.

1.6.3 Traitement des valeurs manquantes

Des valeurs manquantes ont été détectées dans deux colonnes :

- **TOEFL Score**
- **SOP (Statement of Purpose)**

Ces deux colonnes présentaient chacune 37 valeurs manquantes.

La stratégie choisie a été de supprimer toutes les lignes contenant au moins une valeur manquante :

```
df_clean = df.dropna()
```

Puis une vérification a été effectuée pour s'assurer qu'il ne restait plus de données manquantes :

```
df_clean.isnull().sum()
```

Résultat : toutes les valeurs manquantes ont été supprimées. Le jeu de données final contient 513 lignes.

1.6.4 Détection de doublons

Pour vérifier la présence de doublons, j'ai utilisé la commande suivante :

```
df_clean.duplicated().sum()
```

Résultat : aucune ligne dupliquée n'a été détectée.

1.6.5 Étude des valeurs aberrantes

Des diagrammes en boîte (*boxplots*) ont été tracés pour les variables numériques afin de visualiser les potentiels outliers. Bien que certains points soient situés à l'extérieur des moustaches, aucun n'a été jugé significativement aberrant ou incohérent (par exemple, un CGPA supérieur à 10 ou un score GRE supérieur à 340). Aucun traitement particulier n'a été effectué à ce stade.

1.6.6 Étude des corrélations

Une matrice de corrélation a été générée pour évaluer les relations entre les variables :

```
corr_matrix = df_clean.corr()
```

Les coefficients de corrélation les plus élevés avec la variable cible *Chance of Admit* sont :

- **CGPA** : 0.87
- **GRE Score** : 0.82
- **TOEFL Score** : 0.79
- **Research** : 0.55

On constate que les performances académiques (CGPA, GRE, TOEFL) et l'expérience de recherche sont fortement liées aux chances d'admission.

1.6.7 Conclusion de l'exploration

L'analyse exploratoire a permis de :

- Nettoyer le jeu de données (suppression des lignes incomplètes),
- Confirmer l'absence de doublons,
- Identifier les variables les plus corrélées à la cible,
- Préparer les données pour les étapes de visualisation et de modélisation.

Chapitre 2

Visualisation des Données

2.1 Introduction

La visualisation des données constitue une étape cruciale dans l'analyse exploratoire. Elle permet de :

- comprendre la distribution des variables,
- détecter des tendances ou des regroupements,
- observer les relations entre variables explicatives et la variable cible (*Chance of Admit*),
- orienter les choix de modélisation futurs.

Nous distinguons ici deux types d'analyse : univariée (étude d'une seule variable) et bivariée (étude de la relation entre deux variables).

2.2 Analyse univariée

GRE Score



FIGURE 2.1 – Distribution du GRE Score

La majorité des scores GRE se situe entre 300 et 335. Cela montre une répartition relativement homogène avec une concentration autour de scores élevés, ce qui peut refléter un ensemble de candidats compétitifs.

CGPA



FIGURE 2.2 – Distribution du CGPA

On observe une forte concentration des CGPA entre 8.0 et 9.5. Très peu de candidats ont un CGPA inférieur à 7.5. Entre 9.5 et 10, on note aussi une densité significative, indiquant que de nombreux candidats obtiennent des résultats académiques très solides.

TOEFL Score



FIGURE 2.3 – Distribution du TOEFL score

Les scores TOEFL se concentrent principalement entre 100 et 110, ce qui est typique d'étudiants internationaux préparés. Quelques candidats atteignent même des scores supérieurs à 115.

University Rating



FIGURE 2.4 – Distribution de l'évaluation des universités

Les notes d'université sont principalement réparties entre 2 et 4. Très peu de candidats proviennent d'universités notées 1 ou 5, ce qui suggère une tendance vers des établissements modérément bien classés.

Research




FIGURE 2.5 – Répartition des candidats selon l'expérience de recherche

57.1% des candidats ont une expérience de recherche contre 42.9% qui n'en ont pas. Cela souligne que l'expérience de recherche est un critère courant parmi les postulants, possiblement lié à de meilleures chances d'admission.

Chance of Admit



FIGURE 2.6 – Distribution de la probabilité d'admission

La majorité des valeurs de *Chance of Admit* se situe entre 0.6 et 0.8, indiquant une tendance à des profils relativement compétitifs. Une deuxième concentration apparaît entre 0.8 et 0.9, ce qui montre qu'une part non négligeable des candidats a un fort potentiel d'admission.

2.3 Analyse bivariée

GRE Score vs Chance of Admit



FIGURE 2.7 – Relation entre GRE Score et Chance of Admit

La relation est globalement croissante : les candidats ayant un GRE supérieur à 320 ont davantage de chances d'admission. La concentration est maximale pour des GRE compris entre 300 et 330 et des probabilités d'admission entre 0.6 et 0.8.

CGPA vs Chance of Admit



FIGURE 2.8 – Relation entre CGPA et Chance of Admit

Une forte corrélation est visible : plus le CGPA est élevé, plus la probabilité d'admission augmente. L'essentiel des données est concentré entre un CGPA de 8 à 9 et un taux d'admission de 0.6 à 0.8.

TOEFL Score vs Chance of Admit



FIGURE 2.9 – Relation entre TOEFL Score et Chance of Admit

La tendance est similaire : les meilleurs scores TOEFL correspondent à des probabilités d'admission plus élevées. La zone la plus dense concerne des scores TOEFL entre 100 et 110, avec des taux d'admission entre 0.6 et 0.8.

Chance of Admit par expérience de recherche



FIGURE 2.10 – Chance of Admit en fonction de l'expérience de recherche

On note une nette différence entre les deux groupes :

- Les candidats sans recherche (0) ont une médiane d'environ 0.65 avec des valeurs centrées entre 0.55 et 0.7.
- Ceux ayant une expérience de recherche (1) ont une médiane proche de 0.8 et un troisième quartile autour de 0.89.

Cela indique que l'expérience de recherche est clairement liée à une meilleure chance d'admission.

Nombre de candidats selon l'expérience de recherche



FIGURE 2.11 – Répartition des candidats avec ou sans expérience de recherche

Environ 250 à 300 candidats n'ont pas d'expérience de recherche, tandis que 200 à 250 en ont une. Bien que la majorité ait une expérience, l'écart reste relativement modéré.

2.4 Conclusion

Cette exploration graphique met en évidence plusieurs éléments :

- Une corrélation positive entre le GRE, TOEFL, CGPA et la chance d'admission ;
- L'influence nette de l'expérience de recherche sur la probabilité d'être admis ;
- Une distribution relativement équilibrée des candidats sur plusieurs variables, bien que certaines zones de concentration soient identifiables.

Ces observations seront utilisées pour guider les choix de modélisation dans les prochaines sections.

2.5 Présentation du Dataset

Nom du Dataset :

gc_data.csv

Source :

https://sourceforge.net/projects/triangleinequal/files/Grad%20Cafe%20Data/gc_data.csv/download

Les colonnes qui contiennent dans le dataset :

School, Program, Result, Result_Date, GPA, Verbal_GRE, Quant_GRE, Writing_GRE, Subject_GRE, Status, Submit_Date, Degree_Type

Aperçu des 5 premières lignes du dataset :

	Verbal_GRE	Quant_GRE	Writing_GRE	GPA	Admitted
1	153.0	168.0	3.0	3.65	1
2	166.0	163.0	4.0	3.89	1
4	162.0	169.0	3.5	3.84	1
6	164.0	164.0	3.5	4.00	1
11	156.0	163.0	4.5	3.60	1

FIGURE 2.12 – Aperçu des 5 premières lignes du dataset

Matrice de Corrélation :

latex/figures/corr.png

Choix des variables explicatives (X) :

Nous avons sélectionné les variables suivantes comme variables explicatives :

Verbal_GRE, Quant_GRE, Writing_GRE, GPA, Result

Variable cible (Y) :

La variable cible est **Admitted**. Cette variable correspond à notre objectif d'étude, car elle représente la classification binaire 1 pour admit et 0 pour le contraire qui sert à prédire si l'étudiant peut être passer ou pas.

Nom du Dataset :

Australian dataset

Source :

<https://www.kaggle.com/datasets/nasirayub2/australian-student-performancedata-aspd24>

Les colonnes qui contiennent dans le dataset :


51 colonnes dont GPA, High School GPA, Entrance Exam Score, Attendance, Family Income, Parental Education, Health, Mental Health, Exam Scores, Performance ...

Aperçu des 5 premières lignes du dataset :



FIGURE 2.13 – Aperçu des 5 premières lignes du dataset

Matrice de Corrélation :



latex/figures/corr1.png

Choix des variables explicatives (X) :

Nous avons sélectionné les variables suivantes comme variables explicatives :

GPA, Final Exam Scores, Gender, Parental Education Level, Family Income,
Hours of Study per Week

Variable cible (Y) :

La variable cible est **Performance**. Cette variable correspond mais pas à 100% peut être à 70% sur notre objectif d'étude, car elle représente la performance des étudiants mais pas le classe.

Chapitre 3

Modélisation

Dans cette section, nous avons testé plusieurs algorithmes de classification afin de prédire la probabilité d'admission des candidats. Les modèles utilisés sont : **SVM (SVC)**, **Arbre de décision**, **Forêt aléatoire**, **Régression logistique** et **K plus proches voisins (KNN)**. Pour chaque modèle, nous avons appliqué une normalisation des données avec `StandardScaler` et utilisé un pipeline pour enchaîner les étapes.

3.1 Évaluation des modèles

Chaque modèle a été entraîné sur 80% des données et testé sur 20%. Les métriques utilisées pour comparer les performances sont :

- **Accuracy** : proportion de prédictions correctes.
- **Precision** : proportion de vrais positifs parmi les positifs prédits.
- **Recall** : proportion de vrais positifs correctement détectés.
- **F1-score** : moyenne harmonique entre précision et rappel.

3.2 Résultats comparatifs


Les performances globales sont résumées dans le tableau suivant :

Modèle	Accuracy	Précision	Rappel	F1-score
SVC	0.90	0.94	0.91	0.92
Arbre de décision	0.76	0.82	0.82	0.82
Forêt aléatoire	0.87	0.89	0.93	0.91
Régression logistique	0.87	0.92	0.88	0.90
KNN	0.87	0.92	0.88	0.90

TABLE 3.1 – Comparaison des performances des différents modèles.


3.3 Courbes d'apprentissage

Pour mieux comprendre le biais et la variance de chaque modèle, nous avons tracé les courbes d'apprentissage. Ces dernières montrent l'évolution de la performance en fonction de la taille de l'échantillon d'entraînement.

The figure is a learning curve plot for an SVC model. It shows two curves: a training curve and a cross-validation curve. The x-axis represents the number of samples, and the y-axis represents the score. The training curve starts at a high score and decreases as the number of samples increases. The cross-validation curve starts at a lower score and increases as the number of samples increases. The two curves intersect at a point, indicating the optimal number of samples for the model.

figures/learning_curve_svc.png

FIGURE 3.1 – Courbe d'apprentissage pour SVC.



figures/learning_curve_rf.png

FIGURE 3.2 – Courbe d'apprentissage pour Forêt aléatoire.




figures/learning_curve_dtc.png

FIGURE 3.3 – Courbe d'apprentissage pour Arbre de décision.



figures/learning_curve_lr.png

FIGURE 3.4 – Courbe d'apprentissage pour Régression logistique.



figures/learning_curve_knn.png

FIGURE 3.5 – Courbe d'apprentissage pour KNN.

3.4 Discussion

L'analyse comparative montre que :

- Le modèle **SVC** obtient la meilleure performance globale avec un F1-score de 0.92, grâce à une bonne précision et un bon rappel.
- Les modèles **Forêt aléatoire** et **KNN** présentent des résultats proches (accuracy de 0.87 et F1-score de 0.90).
- L'**arbre de décision**, en revanche, a un score plus faible (accuracy 0.76), et tend à sur-apprendre les données d'entraînement (overfitting).
- La **régression logistique** se démarque car, contrairement aux modèles comme l'arbre de décision, la forêt aléatoire ou KNN qui mémorisent fortement les données, elle parvient à **apprendre une véritable relation généralisable entre les variables et la probabilité d'admission**.

Ainsi, même si SVC donne les meilleurs résultats en termes de F1-score, la régression logistique apparaît comme un modèle plus robuste et interprétable pour ce type de problématique. Elle a donc été retenue et sauvegardée pour de futures prédictions.

Chapitre 4

Déploiement

Dans ce chapitre, nous présentons la manière dont le modèle entraîné peut être testé par un utilisateur.

4.1 Test interactif du modèle

Un script Python a été développé pour permettre à l'utilisateur d'entrer ses informations académiques et personnelles afin d'obtenir une prédiction de réussite au concours d'entrée universitaire.

- L'utilisateur renseigne le **GRE Score**, **TOEFL Score**, **Note de l'université**, **SOP**, **LOR**, **CGPA** et l'expérience de **recherche**.
- Pour chaque entrée, si l'utilisateur n'a pas de donnée, une valeur par défaut neutre est utilisée.
- Le script affiche ensuite le résultat de la prédiction :
 - `Candidat probablement admis` si le modèle prédit 1.
 - `Candidat probablement non admis` si le modèle prédit 0.

4.2 Chargement du modèle

Le modèle a été sauvegardé à l'aide de la librairie `pickle` et peut être chargé depuis le fichier `logistic.pkl` pour être utilisé dans le script de test.

4.3 Illustration du script

```
import pickle as pkl
with open('models/logistic.pkl', 'rb') as f:
    model_loaded = pkl.load(f)

test_model_input(model_loaded)
```

Ce script représente une première étape de déploiement dans un environnement local et permet de vérifier le fonctionnement du modèle avant tout déploiement plus complexe.

Chapitre 5

Conclusion

Ce projet a permis de mettre en œuvre un modèle de machine learning capable de prédire les chances d’admission des candidats dans les universités, à partir de différentes informations académiques et personnelles.

Plusieurs étapes ont été franchies avec succès :

- **Préparation des données** : nettoyage et sélection des colonnes pertinentes.
- **Modélisation** : comparaison de plusieurs modèles classiques (SVC, Random Forest, Decision Tree, Logistic Regression, K-Nearest Neighbors) pour identifier celui offrant les meilleures performances.
- **Évaluation** : analyse des métriques de classification (accuracy, précision, recall, F1-score) et visualisation des courbes d’apprentissage.
- **Déploiement local** : implémentation d’un script interactif permettant à l’utilisateur de tester le modèle en fournissant ses propres données.

Les résultats ont montré que le modèle de **Logistic Regression** offrait un compromis intéressant entre précision et capacité d’apprentissage, étant capable de généraliser correctement sur de nouvelles données. Comparé aux autres modèles qui semblaient mémoriser les jeux de données d’entraînement, le modèle logistic a été le seul à réellement apprendre les relations entre les variables.

Enfin, ce projet constitue une base solide pour un futur déploiement plus avancé, pouvant inclure une interface web ou une API, afin de rendre le modèle accessible à un plus grand nombre d’utilisateurs.

Le travail effectué illustre également l’importance de la préparation des données et de l’évaluation rigoureuse des modèles, étapes essentielles dans tout projet de machine learning.