



Projet de Fin d'Études

Analyse Prédictive sur des Données Réelles

Parcours Data Analyst

Année universitaire 2024–2025

Réalisé par : Aritendry Ramahafeno
En collaboration avec : Bernardin RASOLONJANAHARY
Encadré par : Docteur Dimby

Table des matières

Remerciements	2
Résumé	3
Abstract	4
1 Introduction Générale	5
1.1 Contexte	5
1.2 Problématique	5
1.3 Objectifs	5
1.4 Démarche méthodologique	5
1.5 Structure du document	6
1.6 Exploration des données	6
1.6.1 Chargement du jeu de données	6
1.6.2 Aperçu des données	6
1.6.3 Traitement des valeurs manquantes	6
1.6.4 Détection de doublons	7
1.6.5 Étude des valeurs aberrantes	7
1.6.6 Étude des corrélations	7
1.6.7 Conclusion de l'exploration	7

Remerciements

Avant toute chose, nous rendons grâce à Dieu Tout-Puissant, source de toute sagesse et de toute force, pour nous avoir accompagnés tout au long de ce parcours académique, et pour nous avoir accordé la santé, la persévérance et le courage nécessaires à la réalisation de ce projet.

Nous tenons à exprimer notre profonde reconnaissance à Docteur Dimby pour son encadrement rigoureux, ses conseils éclairés et sa disponibilité, qui ont grandement contribué à l'aboutissement de ce travail.

Nos remerciements s'adressent également à l'ensemble des enseignants du département Informatique de l'Institut National Supérieur d'Informatique, pour les connaissances transmises et leur engagement envers notre formation.

Nous remercions également nos camarades de promotion pour leur esprit de collaboration, leur entraide et les moments partagés durant cette année universitaire.

Enfin, nous exprimons toute notre gratitude à nos familles respectives pour leur soutien moral, leurs encouragements constants et leur confiance en nous.

Résumé

Ce projet de fin d'année porte sur la prédiction du taux de réussite au concours d'entrée à l'université. À partir d'un jeu de données comportant plusieurs variables telles que le score GRE, le score TOEFL, la moyenne générale (CGPA), et d'autres facteurs académiques, nous avons nettoyé et analysé les données afin de construire un modèle prédictif performant. Nous avons utilisé un classifieur Random Forest pour estimer la probabilité d'admission d'un candidat. Les résultats obtenus montrent une bonne précision, démontrant que les variables sélectionnées sont pertinentes pour prédire l'admission. Ce travail ouvre la voie à des outils d'aide à la décision pour les futurs candidats et les établissements d'enseignement supérieur.

Abstract

This final year project focuses on predicting the success rate of candidates in university entrance exams. Using a dataset containing variables such as GRE scores, TOEFL scores, GPA, and other academic factors, we cleaned and analyzed the data to build an effective predictive model. A Random Forest classifier was used to estimate the probability of candidate admission. The obtained results show good accuracy, indicating that the selected variables are relevant for predicting admission. This work paves the way for decision support tools for future candidates and higher education institutions.

Chapitre 1

Introduction Générale

1.1 Contexte

L'accès à l'université est un enjeu majeur pour de nombreux étudiants, et les concours d'entrée constituent souvent une étape déterminante. Prédire le taux de réussite à ces concours permet non seulement d'aider les futurs candidats à mieux se préparer, mais aussi d'accompagner les établissements dans leurs processus de sélection.

1.2 Problématique

La prédiction du succès au concours d'entrée est un défi complexe qui repose sur l'analyse de plusieurs facteurs académiques et personnels. Les données disponibles sont souvent volumineuses, hétérogènes et bruitées, ce qui complique l'élaboration de modèles fiables. Il est donc nécessaire de développer des méthodes efficaces pour traiter ces données et produire des prédictions précises.

1.3 Objectifs

L'objectif principal de ce projet est de construire un modèle prédictif capable d'estimer la probabilité de réussite des candidats au concours d'entrée à l'université, à partir de données académiques telles que les scores aux tests standardisés (GRE, TOEFL), la moyenne générale et d'autres variables pertinentes.

1.4 Démarche méthodologique

Pour atteindre cet objectif, nous avons collecté plusieurs jeux de données, puis procédé à une sélection rigoureuse afin de retenir celui offrant la meilleure qualité et fiabilité. Les données ont été nettoyées, transformées et analysées exploratoirement. Ensuite, différents modèles d'apprentissage automatique ont été testés, évalués et comparés, pour finalement retenir le plus performant.

1.5 Structure du document

Ce rapport est organisé en plusieurs parties. La première partie présente l'étude et la préparation des données. La deuxième partie détaille la modélisation, les choix et évaluations des algorithmes. La troisième partie analyse les résultats obtenus. Enfin, la dernière partie propose des perspectives d'amélioration et de déploiement futur.

1.6 Exploration des données

1.6.1 Chargement du jeu de données

Le jeu de données a été chargé au format CSV à l'aide de la bibliothèque `pandas` :

```
import pandas as pd
df = pd.read_csv("admission_data.csv")
```

La commande `df.info()` a permis d'obtenir un aperçu des colonnes, de leurs types et du nombre de valeurs non nulles. On compte 9 colonnes et 550 lignes.

1.6.2 Aperçu des données

- Le jeu de données contient des variables quantitatives continues (*GRE Score*, *TOEFL Score*, *CGPA*, *Chance of Admit*) et discrètes (*University Rating*, *SOP*, *LOR*, *Research*).
- L'attribut *Chance of Admit* est la variable cible. Elle indique la probabilité d'admission.

1.6.3 Traitement des valeurs manquantes

Des valeurs manquantes ont été détectées dans deux colonnes :

- **TOEFL Score**
- **SOP (Statement of Purpose)**

Ces deux colonnes présentaient chacune 37 valeurs manquantes.

La stratégie choisie a été de supprimer toutes les lignes contenant au moins une valeur manquante :

```
df_clean = df.dropna()
```

Puis une vérification a été effectuée pour s'assurer qu'il ne restait plus de données manquantes :

```
df_clean.isnull().sum()
```

Résultat : toutes les valeurs manquantes ont été supprimées. Le jeu de données final contient 513 lignes.

1.6.4 Détection de doublons

Pour vérifier la présence de doublons, j'ai utilisé la commande suivante :

```
df_clean.duplicated().sum()
```

Résultat : aucune ligne dupliquée n'a été détectée.

1.6.5 Étude des valeurs aberrantes

Des diagrammes en boîte (*boxplots*) ont été tracés pour les variables numériques afin de visualiser les potentiels outliers. Bien que certains points soient situés à l'extérieur des moustaches, aucun n'a été jugé significativement aberrant ou incohérent (par exemple, un CGPA supérieur à 10 ou un score GRE supérieur à 340). Aucun traitement particulier n'a été effectué à ce stade.

1.6.6 Étude des corrélations

Une matrice de corrélation a été générée pour évaluer les relations entre les variables :

```
corr_matrix = df_clean.corr()
```

Les coefficients de corrélation les plus élevés avec la variable cible *Chance of Admit* sont :

- **CGPA** : 0.87
- **GRE Score** : 0.82
- **TOEFL Score** : 0.79
- **Research** : 0.55

On constate que les performances académiques (CGPA, GRE, TOEFL) et l'expérience de recherche sont fortement liées aux chances d'admission.

1.6.7 Conclusion de l'exploration

L'analyse exploratoire a permis de :

- Nettoyer le jeu de données (suppression des lignes incomplètes),
- Confirmer l'absence de doublons,
- Identifier les variables les plus corrélées à la cible,
- Préparer les données pour les étapes de visualisation et de modélisation.