



---

===== lllllll 7f1856b (Ajustement du livre)



# Predicition du taux de reussite au concours d'entré école/université

Parcours Intelligence Artificielle

**Année universitaire 2024–2025**

Réalisé par : Aritendry RAMAHAFENO

Et : Bernardin RASOLONJANAHARY

Encadré par : Dr ANDRIAMAHAZOSOA Dimbinantenaina Rabearivony



---

«««< HEAD =====

# Présentation de l'INSI

## 1. Information d'ordre général

INSI (Institut National Supérieur d'Informatique) est un institut universitaire situé à Antananarivo, spécialisé dans le domaine de l'informatique. Il accueille principalement des bacheliers ayant choisi cette filière, mais reste également ouvert à toute personne manifestant un intérêt particulier pour les métiers du numérique, à travers son centre de formation professionnelle.

L'établissement a été fondé le **17 août 2021** et son siège se trouve à **Ankazotokana Ambanidia, Lot VF 32 Ter**.

Pour tout renseignement, vous pouvez nous contacter par email à **contact@insi.mg** ou visiter notre site web : **www.insi.mg**

INSI University bénéficie du soutien d'entreprises partenaires, dont **Ilo Madagascar SARLU** et **Data Pulse Center**, qui sont également à l'origine de sa création.

## 2. Missions et historiques

INSI University a été fondée le **17 août 2021** à Antananarivo, dans un contexte marqué par une forte demande de compétences dans le domaine de l'informatique et des technologies numériques,

Créé à l'initiative de **Ilo Madagascar SARLU** et **Data Pulse Center**, l'Institut a vu le jour avec pour ambition de former une nouvelle génération de professionnels qualifiés, capables de répondre aux besoins du marché local et international.

Depuis sa création, INSI ne cesse d'évoluer en adaptant ses formations aux enjeux technologiques actuels, tout en favorisant un apprentissage pratique, orienté vers les réalités du monde professionnel.


La mission principale de l'INSI est de **former des experts compétents, éthiques et innovants dans le domaine de l'informatique**, capables de contribuer activement au développement économique et numérique de Madagascar.

L'Institut s'engage à :

- Offrir des formations de qualité, à jour des évolutions technologiques,
- Favoriser l'insertion professionnelle de ses apprenants,
- Créer un lien fort entre la formation académique et les besoins réels des entreprises,
- Encourager l'entrepreneuriat et l'innovation technologique,
- Contribuer à la démocratisation de l'accès au savoir numérique.

## 1. Organigramme de l'INSI

L'organigramme ci-dessous présente la structure organisationnelle de l'INSI, mettant en évidence les différentes fonctions et responsabilités au sein de l'institut, ainsi que les liens hiérarchiques entre les divers services.



**Figure 1 : Organigramme de l'INSI**

L'organigramme de l'INSI, en partenariat avec le Collège de Paris, est structuré autour d'une direction générale incarnée par le Président Directeur Général. Ce dernier assure la coordination de trois pôles principaux : la Direction Administrative et Financière, la Direction des Études, et le service des Relations Internationales et Mobilités.

Le **Président Directeur Général** assure la direction stratégique de l'institut. Il supervise l'ensemble des activités pédagogiques, administratives et de développement.

Il veille à la qualité de l'enseignement, à la bonne gestion des ressources humaines et matérielles, et représente l'établissement auprès des partenaires et autorités.

La **Direction Administrative et Financière** est chargée de la gestion des affaires internes, notamment à travers deux services essentiels : le service des **scolarités**, qui s'occupe des dossiers étudiants, inscriptions et suivi académique, et les **services supports et stratégiques**, qui assurent un appui logistique, administratif et technologique à l'ensemble de l'institut.

Le pôle des **Relations Internationales et Mobilités** gère les échanges académiques avec l'étranger ainsi que les projets de mobilité étudiante ou enseignante.

La **Direction des Études** supervise quant à elle l'ensemble des programmes pédagogiques et le corps enseignant. Elle travaille en étroite collaboration avec un **Responsable Parcours**, qui coordonne les différentes spécialisations proposées. Cette direction intègre

également une cellule dédiée à la **formation professionnelle et à la certification**, en charge des dispositifs de validation des compétences, des certifications professionnelles et des parcours de formation continue. Il comprend également le **Département alternance et emplois**, responsable du suivi des étudiants en contrat d'alternance, des stages professionnels, et de l'insertion professionnelle.

Sous la partie **Responsable Parcours**, plusieurs responsables pédagogiques gèrent les différentes filières de formation : le **parcours tronc commun**, qui regroupe les matières fondamentales partagées par tous les étudiants en début de cycle ; le **parcours ARSB & IC** ; le **parcours GL & MSI** ; et enfin le **parcours IAD & I2AD**.

D'autres structures, bien que non représentés sur cet organigramme, contribuent également de manière significative à la mission de l'INSI.

Le **Conseil de l'École**, Il regroupe des membres de l'équipe pédagogique et administrative. Il joue un rôle consultatif ou décisionnel sur les questions académiques : validation des programmes, suivi des résultats, discipline, méthodologie, etc.

Le **responsable de la formation en ligne**, Il conçoit et supervise les dispositifs d'apprentissage à distance. Il s'assure que les contenus en ligne sont accessibles, interactifs et conformes aux standards pédagogiques, tout en accompagnant enseignants et étudiants dans leur utilisation.

L'**Association et Clubs étudiants**, encadre et soutient les initiatives étudiantes, les clubs thématiques (informatique, innovation, sport, culture, etc.), et les événements organisés dans le cadre de la vie étudiante. Cela favorise l'engagement, le développement personnel et les compétences transversales des étudiants.

Cette structure témoigne d'une organisation à la fois pédagogique, administrative et tournée vers l'international et l'employabilité, assurant une formation complète et professionnalisante aux étudiants.

## 2. Domaine de spécialisation

INSI University propose des **parcours académiques professionnalisants** dans le domaine de l'informatique et des technologies numériques, articulés autour de licences professionnelles, de masters spécialisés, formations professionnelles continues et d'opportunités de mobilité internationale.

### a) Licences professionnelles

Les programmes de licence offrent une formation de base solide, axée sur la pratique, et préparant à une insertion rapide dans le monde professionnel :

**GL (Génie Logiciel)** : Conception, développement et maintenance d'applications logicielles.

**ARSB (Administration Réseaux et Systèmes et Base de données)** : Gestion d'infrastructures informatiques, réseaux, serveurs et systèmes.

**IAD (Intelligence Artificielle et Data Science)** : Introduction aux algorithmes d'IA, au traitement de données et à l'apprentissage automatique.

### b) Masters professionnels

Les masters permettent d'approfondir les compétences techniques et managériales, en lien étroit avec les évolutions du secteur :

**MSI (Management des Systèmes d'Information)** : Pilotage de projets numériques, gouvernance des SI.

**IC (Infrastructures et Cybersécurité)** : Sécurisation des systèmes, audit, réseaux avancés.



**I2AD (Intelligence Artificielle, Analyse de Données et Automatisation) :**  
Applications avancées de l'IA, automatisation des processus et science des données.

### c) Formations professionnelles

INSI University propose également des formations professionnelles continues, spécifiquement conçues pour les professionnels déjà en poste souhaitant approfondir leurs compétences ou se spécialiser dans l'un des domaines proposés.

Ces formations sont adaptées aux contraintes des professionnels (horaires flexibles, modules pratiques) et visent à renforcer leur employabilité ou à accompagner leur évolution de carrière.

### d) Mobilité internationale & double diplôme

Dans une optique d'ouverture et de reconnaissance internationale, INSI propose à ses étudiants des opportunités de mobilité académique et de double diplôme, à partir de la deuxième année (L2).

- **Format hybride** : 6 mois de formation à Madagascar + 6 mois à l'étranger selon le parcours choisi.
- **Double diplôme en L3 ou M2** : En partenariat avec des institutions internationales telles que :
  - Collège de Paris (France)
  - Keyce Informatique (France)
  - Eskills (Québec, Canada)

### Conditions d'éligibilité

- Niveau **DALF C1** en français pour la mobilité vers des pays francophones.
- Niveau **B2 ou C1** en anglais pour les destinations anglophones.

### 1. Architectures des formations pédagogiques

Le recrutement des étudiants à l'INSI s'effectue exclusivement par sélection de dossiers pour l'entrée en première année de Licence (L1), et par voie de concours pour l'admission en Master 1,

Au sein de l'INSI, une seule mention est proposée : Informatique, déclinée en trois parcours distincts aux niveaux Licence et Master :

#### Tableau 1 : Les parcours en Licence et Master

||@ >p() \* 0.5021 >p() \* 0.4979@

() Licence

Master

---

() Génie Logiciel (GL) Management des Systèmes d'Information (MSI)  
Administration Réseaux, Systèmes et Bases de données (ARSB) Infrastructures et Cybersécurités (IC)  
Intelligence Artificielle et Data Science (IAD) Intelligence Artificielle, Analyse de Données et Automatisation (I2AD)

---

()

L'architecture des études à trois niveaux conformément au système LMD (Licence Master et Doctorat) permet les comparaisons et les équivalences académiques des diplômes au niveau international.

L = Licence (Bac + 3) = L1, L2, L3 = 6 semestres **S1 à S6**

M = Master (Bac + 5) = M1, M2 = 4 **semestres S7 à S10**

Le diplôme de licence est obtenu en 3 années des études après Baccalauréat. Et le diplôme de Master est obtenu en 2 ans après obtenu du diplôme de LICENCE.

Le MASTER PROFESSIONNEL est un diplôme destiné à la recherche emploi au terme

des études.

### **Spécificités pédagogiques**

#### — **École d'alternance dès la L2 S4**

Alternance cours/entreprise pour une meilleure insertion

#### — **Écoles connectées & e-learning**

Plateforme numérique de formation, cloud intégré, Google Workspace

Cours accessibles en ligne selon les parcours

#### — **Pédagogie active & par projets**

**Hackathons, soutenances exposées, projets réels en entreprise**

### **1. Relations de l'INSI avec les entreprises et les organismes**

L'Institut National Supérieur en Informatique (INSI) entretient des liens étroits avec le monde professionnel. L'INSI collabore activement avec de nombreux organismes publics, semi-publics et privés, tant au niveau national qu'international. Cette collaboration se traduit concrètement par l'organisation régulière de stages obligatoires pour les étudiants, favorisant leur immersion professionnelle et leur employabilité.

Parmi les entreprises et institutions partenaires accueillant nos étudiants en stage chaque année, on peut citer : Data Pulse Center, RELIA Consulting, Code Talent, Bocasay, Minimad, Smartone AI, NOVITY, Eclasia Madagascar, VISEO Groupe, Océane Trade, ACCES Banque, ...

En plus des stages, l'INSI organise régulièrement des **visites pédagogiques**, des **rencontres métiers** et des **projets collaboratifs** avec plusieurs entreprises du secteur technologique et numérique. Ces activités permettent aux étudiants de mieux comprendre les réalités du terrain, d'échanger avec des professionnels et de s'ouvrir à l'environnement entrepreneurial.

Parmi les entreprises ayant accueilli ces initiatives : NOVITY, YAS Madagascar, Smartone AI, Eclasia Madagascar, et d'autres acteurs majeurs du numérique à Madagascar.

Cette dynamique de partenariat permanent constitue un pilier de la pédagogie à l'INSI, en lien avec son objectif de former des professionnels compétents, opérationnels et ancrés dans les besoins du marché.

### **2. Partenariat au niveau international**

L'INSI s'est inscrit dans une dynamique d'ouverture à l'international grâce à son partenaire fondateur, **ILO Madagascar**, représentant de l'Organisation Internationale du Travail. Cette orientation se renforce aujourd'hui à travers des **partenariats stratégiques avec des institutions académiques et des entreprises internationales**, permettant à l'Institut de proposer une formation alignée sur les standards mondiaux.

L'INSI bénéficie actuellement de **programmes de co-diplomation et de double diplôme** en collaboration avec plusieurs établissements internationaux de renom, tels que :

#### — **Collège de Paris International**

#### — **Keyce Informatique (France)**

#### — **Eskills Academy (Québec, Canada)**

- **École Supérieure Polytechnique d’Antsiranana (ESPA)** – pour une synergie régionale renforcée.

Ces partenariats permettent non seulement d’enrichir l’offre pédagogique, mais aussi d’ouvrir des perspectives de **mobilité académique** et **professionnelle** aux étudiants, en leur offrant une reconnaissance de leurs compétences à l’échelle internationale.

Par ailleurs, à travers les **stages annuels** et **projets pédagogiques**, l’INSI collabore également avec des entreprises à dimension régionale ou mondiale, telles que :

- **WISEO Groupe**
- **Eclosia Madagascar** (Groupe mauricien)
- **Smartone AI**
- **NOVITY**, entre autres.

Ces relations actives témoignent de l’ancrage de l’INSI dans un **écosystème global**, plaçant l’Institut comme un acteur majeur de la formation en informatique à Madagascar, tourné vers l’innovation et les exigences du marché international.

### 1. Parcours professionnels des diplômés

Les diplômés de la Licence en Informatique de l’INSI disposent d’un socle solide de compétences en programmation, systèmes, réseaux, bases de données et développement logiciel. Cette polyvalence leur permet d’intégrer directement le marché du travail ou de poursuivre en Master. À ce niveau, ils peuvent exercer en tant que :

- **Technicien système et réseau**
- **Développeur web / mobile (front-end ou back-end)**
- **Administrateur systèmes junior**
- **Technicien support IT**
- **Intégrateur / testeur logiciel**
- **Assistant en sécurité informatique**
- **Assistant en projets d’IA ou de data (selon profil)**

Les stages annuels en entreprise leur offrent une première expérience professionnelle valorisante dans des structures variées : entreprises technologiques, banques, administrations, startups, ONG, etc.

La formation de Master proposée à l’INSI, grâce à ses parcours spécialisés, forme des professionnels capables d’intervenir sur des projets complexes, innovants et à dimension stratégique. Les débouchés varient selon la spécialisation choisie :

#### **Parcours Ingénierie logicielle, réseaux et systèmes :**

- **Ingénieur en développement logiciel / full-stack**
- **Architecte logiciel**
- **Ingénieur systèmes et réseaux**
- **Administrateur cloud / DevOps**
- **Chef de projet informatique**

#### **Parcours Cybersécurité :**

- **Expert en sécurité des systèmes d’information**
- **Analyste SOC / CERT**
- **Auditeur en cybersécurité**
- **Responsable de la sécurité IT (RSSI)**

### Parcours Intelligence Artificielle et Data :

- Data Scientist
- Data Analyst
- Ingénieur en Intelligence Artificielle
- Machine Learning Engineer
- Développeur d'applications intelligentes
- Consultant en IA
- Spécialiste en traitement automatique du langage naturel (TALN)
- Spécialiste en vision par ordinateur (Computer Vision)

Grâce aux **partenariats internationaux** et aux **projets en entreprise**, les diplômés du Master peuvent également prétendre à des postes dans des structures **multinationales**, ou poursuivre une carrière **académique et de recherche** (doctorat, enseignement supérieur).

#### 1. Ressources humaines

L'INSI s'appuie sur une équipe pédagogique et administrative compétente, dynamique et engagée dans la réussite de ses étudiants. Ses ressources humaines se répartissent comme suit :

Président Directeur de l'INSI : Dr RAMASONDRANO Andriamanjaka

Responsable parcours ARSB & IC : Mr RATIANARISON Hery Mampionona

Responsable parcours tronc commun : Dr RAKOTONDRAMANANA R, Sitraka

Responsable parcours GL & MSI : Mr ANDRIAMIADANA TANTELY ANTOINE

Responsable parcours IAD & I2AD : par intérim PDG

Nombres des enseignants : 40

Nombres des personnels administratives : 04

Personnels d'appui : 6

»»»> 7f1856b (Ajustement du livre)

# Predicton du taux de reussite au concours d'entré école/université

Auteur : Aritendry RAMAHAFENO et Bernardin  
RASOLONJANAHARY

# Remerciements

D'abord, on veut vraiment dire merci à Dieu qui nous a accompagnés pendant tout ce projet de fin d'études. Sans Sa grâce, on aurait pas eu la force ni le courage d'aller au bout.

On tient aussi à remercier le Dr ANDRIAMAHAZOSOA Dimbinantenaina Rabearivony qui nous a supervisés. Ses conseils et sa disponibilité ont été super précieux pour nous, surtout quand on bloquait sur certains points.

Un grand merci aussi à tous les profs du département d'Informatique de l'INSI. Les cours qu'on a eus pendant les deux semestres nous ont vraiment préparés pour ce projet.

Et pour finir, merci du fond du cœur à nos familles. Leur soutien et leurs encouragements ont été super importants pour nous, surtout dans les moments un peu difficiles.

# Résumé

Dans projet de fin d'études, on s'est penché sur la prédiction des chances de réussite aux concours d'entrée à l'université. On est parti d'un jeu de données avec différentes variables académiques - les scores GRE et TOEFL, la moyenne générale CGPA, et quelques autres critères qui peuvent jouer.

Le travail consiste d'abord à nettoyer et préparer ces données, puis à tester plusieurs approches de modélisation. On a opté pour une forêt aléatoire (Random Forest) qui nous a donné le meilleur résultat, avec la précision de 90%.

«««< HEAD =====

# Abstract

»»»> 7f1856b (Ajustement du livre)

This final year project tackles the prediction of success rates in university entrance exams. We worked with a dataset containing various academic indicators including GRE and TOEFL scores, CGPA, and other relevant factors that might influence admission chances.

The work involved cleaning and preparing the data, then experimenting with different modeling approaches. We ultimately selected a Random Forest classifier which showed the best performance in predicting candidate admission with an accuracy of 90%.



# Table des matières

|                                                   |            |
|---------------------------------------------------|------------|
| <b>Remerciements</b>                              | <b>III</b> |
| <b>Résumé</b>                                     | <b>V</b>   |
| <b>Abstract</b>                                   | <b>VII</b> |
| <b>1 Introduction Générale</b>                    | <b>1</b>   |
| 1.1 Contexte . . . . .                            | 1          |
| 1.2 Problématique . . . . .                       | 1          |
| 1.3 Objectifs . . . . .                           | 1          |
| 1.4 Démarche suivie . . . . .                     | 1          |
| 1.5 Structure du rapport . . . . .                | 2          |
| <b>2 Exploration des données</b>                  | <b>3</b>   |
| 2.1 Introduction . . . . .                        | 3          |
| 2.1.1 Chargement du jeu de données . . . . .      | 3          |
| 2.1.2 Aperçu des données . . . . .                | 3          |
| 2.1.3 Traitement des valeurs manquantes . . . . . | 4          |
| 2.1.4 Détection de doublons . . . . .             | 4          |
| 2.1.5 Étude des valeurs aberrantes . . . . .      | 4          |
| 2.1.6 Étude des corrélations . . . . .            | 4          |
| 2.1.7 Conclusion de l'exploration . . . . .       | 5          |
| 2.2 Présentation du Dataset . . . . .             | 5          |
| 2.3 Visualisation des Données . . . . .           | 9          |
| 2.4 Analyse univariée . . . . .                   | 9          |
| 2.5 Analyse bivariée . . . . .                    | 15         |
| 2.6 Conclusion de l'exploration . . . . .         | 19         |
| <b>3 Modélisation</b>                             | <b>21</b>  |
| 3.1 Évaluation des modèles . . . . .              | 21         |
| 3.2 Résultats obtenus . . . . .                   | 21         |
| 3.3 Courbes d'apprentissage . . . . .             | 22         |
| 3.4 Analyse des résultats . . . . .               | 24         |
| <b>4 Déploiement</b>                              | <b>27</b>  |
| 4.1 Test interactif du modèle . . . . .           | 27         |
| 4.2 Chargement du modèle . . . . .                | 27         |
| 4.3 Exemple d'utilisation . . . . .               | 27         |

---

|                      |           |
|----------------------|-----------|
| <b>5 Conclusion</b>  | <b>29</b> |
| <b>Annexes</b>       | <b>31</b> |
| <b>Bibliographie</b> | <b>41</b> |

# Chapitre 1

## Introduction Générale

### 1.1 Contexte

L'entrée à l'université représente un enjeu important pour beaucoup d'étudiants, et les concours d'admission sont souvent une étape décisive. Pouvoir prédire les chances de réussite permet non seulement d'aider les candidats à mieux se préparer, mais aussi d'accompagner les établissements dans leur processus de sélection.

### 1.2 Problématique

Prédire si un candidat va réussir son concours d'entrée est un vrai défi : les données sont nombreuses par exemple dans Kaggle sur <https://www.kaggle.com/datasets/samsonqian/college-admissions> . Difficile, dans ces conditions, de bâtir un modèle fiable. Il fallait donc trouver une manière efficace de traiter ces informations pour en tirer des prédictions utiles.

### 1.3 Objectifs

L'objectif de ce projet est de développer un modèle capable d'estimer les probabilités de réussite au concours, en se basant sur des données académiques et les variables pertinents comme les scores au GRE ou au TOEFL, la moyenne générale.

### 1.4 Démarche suivie

«««< HEAD Pour y parvenir, on a commencé par rassembler plusieurs jeux de données, puis on en a choisi un — le plus complet et fiable c'est à dire ce qui correspond le plus au sujet. Ensuite, on a nettoyé et préparé les données, avant de les explorer pour bien comprendre ce qu'elles contenaient. Plusieurs algorithmes de machine learning ont été testés et comparés pour sélectionner celui qui donnait les meilleurs résultats comme la LogisticRegression avec le resultat de 87%, 90% avec SVC, 76% avec Decision Tree, 87% avec Random Forests et 89% avec K-Nearest Neighbors . ===== Pour y parvenir, on a commencé par rassembler plusieurs jeux de données, puis on en a choisi un — le plus complet dont les variables dans les jeux de données sont tous utiles et fiables dont chaque jeu de données n'a pas été falsifié. Ensuite, on a nettoyé et préparé les données,

avant de les explorer pour bien comprendre ce qu'elles contenaient. Plusieurs algorithmes de machine learning ont été testés et comparés pour sélectionner celui qui donnait les meilleurs résultats comme la LogisticRegression avec le resultat de 87%, 90% avec SVC, 76% avec Decision Tree, 87% avec Random Forests et 89% avec K-Nearest Neighbors .  
»»»> 7f1856b (Ajustement du livre)

## 1.5 Structure du rapport

Ce mémoire est organisé en quatre parties :

- La première partie présente la collecte et le prétraitement des données.
- La deuxième détaille la modélisation et l'évaluation des différents algorithmes.
- La troisième analyse les résultats et les performances du modèle retenu.
- Enfin, la dernière partie discute des limitations et propose des pistes d'amélioration pour aller plus loin.

# Chapitre 2

## Exploration des données

### 2.1 Introduction

La visualisation des données constitue une étape cruciale dans l'analyse exploratoire. Elle permet de :

- comprendre la distribution des variables,
- détecter des tendances ou des regroupements,
- observer les relations entre variables explicatives et la variable cible (*Chance of Admit*),
- orienter les choix de modélisation futurs.

Nous distinguons ici deux types d'analyse : univariée (étude d'une seule variable) et bivariée (étude de la relation entre deux variables).

#### 2.1.1 Chargement du jeu de données

Le jeu de données a été chargé au format .CSV à l'aide de la bibliothèque python pandas :

```
import pandas as pd
df = pd.read_csv("admission_data.csv")
```

La commande `df.info()` permet de voir une partie des colonnes, de leurs types et du nombre de valeurs non nulles. On compte 9 colonnes et 550 lignes.

#### 2.1.2 Aperçu des données

«««< HEAD

- Le jeu de données contient des variables quantitatives comme (*GRE Score*, *TOEFL Score*, *CGPA*, *Chance of Admit*) et discrètes (*University Rating*, *SOP*, *LOR*, *Research*).
  - Ici *Chance of Admit* est la variable cible. Elle indique la probabilité d'admission.
- Source du dataset : <https://dr-raz.org/statistical-literacy-csv-data>

=====

Le jeu de données principale que nous avons utilisé contient des variables quantitatives comme (*GRE Score*, *TOEFL Score*, *CGPA*, *Chance of Admit*) et discrètes (*University Rating*, *SOP*, *LOR*, *Research*).

Ici *Chance of Admit* est la variable cible. Elle indique la probabilité d'admission. Source du dataset : <https://dr-raz.org/statistical-literacy-csv-data>

On a aussi eu des jeux de données secondaires qu'on a scrapés comme celle de chez <https://www.thegradcafe.com/survey/>, des jeux de données de chez kaggle aussi <https://www.kaggle.com/datasets/nasirayub2/australian-student-performancedata-aspd24> »»»> 7f1856b (Ajustement du livre)

### 2.1.3 Traitement des valeurs manquantes

Des valeurs manquantes ont été détectées dans deux colonnes :

- **TOEFL Score**

- **SOP (Statement of Purpose)**

Ces deux colonnes présentaient chacune 37 valeurs manquantes.

La stratégie choisie a été de supprimer toutes les lignes contenant au moins une valeur manquante :

```
df_clean = df.dropna()
```

Puis on a fait une vérification pour s'il n'y a plus de variable manquantes dans le dataset

```
df_clean.isnull().sum()
```

Résultat : toutes les valeurs manquantes ont été supprimées. Le jeu de données final contient 513 lignes.

### 2.1.4 Détection de doublons

Pour vérifier la présence de doublons, j'ai utilisé la commande suivante :

```
df_clean.duplicated().sum()
```

Résultat : aucune ligne dupliquée n'a été détectée.

### 2.1.5 Étude des valeurs aberrantes

Des diagrammes en boîte (*boxplots*) ont été tracés pour les variables numériques afin de visualiser les potentiels outliers. Bien que certains points soient situés à l'extérieur du graphe de boîtes à moustache, aucun n'a été jugé significativement aberrant ou incohérent (par exemple, un CGPA supérieur à 10 ou un score GRE supérieur à 340). Aucun traitement particulier n'a été effectué à ce niveau.

### 2.1.6 Étude des corrélations

Une matrice de corrélation a été générée pour évaluer les relations entre les variables :

```
corr_matrix = df_clean.corr()
```

Les coefficients de corrélation les plus élevés avec la variable cible *Chance of Admit* sont :

| Critère     | Valeur |
|-------------|--------|
| CGPA        | 0.87   |
| GRE Score   | 0.82   |
| TOEFL Score | 0.79   |
| Research    | 0.55   |

On voit que les performances académiques (CGPA, GRE, TOEFL) et l'expérience de recherche sont fortement corrélés aux chances d'admission.

### 2.1.7 Conclusion de l'exploration

L'analyse exploratoire a permis de :

- Nettoyer le jeu de données (suppression des lignes incomplètes),
- Confirmer l'absence de doublons,
- Identifier les variables les plus corrélées à la cible,
- Préparer les données pour les étapes de visualisation et de modélisation.

## 2.2 Présentation du Dataset

**Nom du Dataset :** gc\_data.csv


**Les colonnes du le dataset :**

- School, Program, Result, Result\_Date, GPA,
- Verbal\_GRE, Quant\_GRE, Writing\_GRE, Subject\_GRE,
- Status, Submit\_Date, Degree\_Type

**Aperçu des 5 premières lignes du dataset :**

|    | Verbal_GRE | Quant_GRE | Writing_GRE | GPA  | Admitted |
|----|------------|-----------|-------------|------|----------|
| 1  | 153.0      | 168.0     | 3.0         | 3.65 | 1        |
| 2  | 166.0      | 163.0     | 4.0         | 3.89 | 1        |
| 4  | 162.0      | 169.0     | 3.5         | 3.84 | 1        |
| 6  | 164.0      | 164.0     | 3.5         | 4.00 | 1        |
| 11 | 156.0      | 163.0     | 4.5         | 3.60 | 1        |

FIGURE 2.1 – Aperçu des 5 premières lignes du dataset



### Choix des variables explicatives (X) :

Nous avons sélectionné les variables suivantes comme variables explicatives :

- Verbal\_GRE
- Quant\_GRE
- Writing\_GRE
- GPA
- Result

### Variable cible (Y) :

La variable cible est **Admitted**. Cette variable correspond à notre objectif d'étude, car elle représente la classification binaire 1 pour admit et 0 pour le contraire qui sert à prédire si l'étudiant peut être passer ou pas.

### Nom du Dataset :

Australian dataset c'est une donnée des étudiants de l'Australie

### Les colonnes dans le dataset :

51 colonnes y compris :

- GPA
- High School GPA
- Entrance Exam Score
- Attendance
- Family Income



- Parental Education
- Health
- Mental Health
- Exam Scores
- Performance

**Aperçu des 5 premières lignes du dataset :**

|   | Student ID | University ID | University Name | Age | Gender | Major | Year of Study | GPA  | High School GPA | Entrance Exam Score | ... |
|---|------------|---------------|-----------------|-----|--------|-------|---------------|------|-----------------|---------------------|-----|
| 0 | 1          | 86            | University C    | 25  | F      | EE    | 1             | 2.06 | 3.50            | 60                  | ... |
| 1 | 2          | 17            | University A    | 26  | F      | ME    | 4             | 2.12 | 3.46            | 52                  | ... |
| 2 | 3          | 52            | University C    | 20  | M      | CS    | 4             | 2.72 | 3.33            | 94                  | ... |
| 3 | 4          | 91            | University A    | 25  | M      | ME    | 1             | 3.05 | 3.54            | 65                  | ... |
| 4 | 5          | 33            | University C    | 22  | F      | CE    | 3             | 1.86 | 3.35            | 51                  | ... |

FIGURE 2.2 – Les 5 premières lignes du dataset

### Choix des variables explicatives (X) :

Nous avons sélectionné les variables suivantes comme variables explicatives :

- GPA
- Final Exam Scores
- Gender
- Parental Education Level
- Family Income
- Hours of Study per Week

### Variable cible (Y) :

La variable cible est **Performance**. Cette variable correspond mais pas à 100% peut être à 70% sur notre objectif d'étude, car elle représente la performance des étudiants mais pas le classe.




FIGURE 2.3

## 2.3 Visualisation des Données

## 2.4 Analyse univariée

### GRE Score




FIGURE 2.4 – Distribution du GRE Score

La majorité des scores GRE se situe entre 300 et 335. Cela montre une répartition relativement homogène avec une concentration autour de scores élevés, ce qui peut refléter un ensemble de candidats compétitifs.

## CGPA




FIGURE 2.5 – Distribution du CGPA

On observe une forte concentration des CGPA entre 8.0 et 9.5. Très peu de candidats ont un CGPA inférieur à 7.5. Entre 9.5 et 10, on note aussi une densité significative, indiquant que de nombreux candidats obtiennent des résultats académiques très solides.

## TOEFL Score




FIGURE 2.6 – Distribution du TOEFL score

Les scores TOEFL se concentrent principalement entre 100 et 110, ce qui est typique d'étudiants internationaux préparés. Quelques candidats atteignent même des scores supérieurs à 115.

## University Rating




FIGURE 2.7 – Distribution de l'évaluation des universités

Les notes d'université sont principalement réparties entre 2 et 4. Très peu de candidats proviennent d'universités notées 1 ou 5, ce qui suggère une tendance vers des établissements modérément bien classés.

## Research




FIGURE 2.8 – Répartition des candidats selon l'expérience de recherche

57.1% des candidats ont une expérience de recherche contre 42.9% qui n'en ont pas. Cela souligne que l'expérience de recherche est un critère courant parmi les postulants, possiblement lié à de meilleures chances d'admission.

## Chance of Admit




FIGURE 2.9 – Distribution de la probabilité d'admission

La majorité des valeurs de *Chance of Admit* se situe entre 0.6 et 0.8, indiquant une tendance à des profils relativement compétitifs. Une deuxième concentration apparaît entre 0.8 et 0.9, ce qui montre qu'une part non négligeable des candidats a un fort potentiel d'admission.



## 2.5 Analyse bivariée

### GRE Score vs Chance of Admit




FIGURE 2.10 – Relation entre GRE Score et Chance of Admit

La relation est globalement croissante : les candidats ayant un GRE supérieur à 320 ont davantage de chances d'admission. La concentration est maximale pour des GRE compris entre 300 et 330 et des probabilités d'admission entre 0.6 et 0.8.

## CGPA vs Chance of Admit




FIGURE 2.11 – Relation entre CGPA et Chance of Admit

Une forte corrélation est visible : plus le CGPA est élevé, plus la probabilité d'admission augmente. L'essentiel des données est concentré entre un CGPA de 8 à 9 et un taux d'admission de 0.6 à 0.8.

## TOEFL Score vs Chance of Admit




FIGURE 2.12 – Relation entre TOEFL Score et Chance of Admit

La tendance est similaire : les meilleurs scores TOEFL correspondent à des probabilités d'admission plus élevées. La zone la plus dense concerne des scores TOEFL entre 100 et 110, avec des taux d'admission entre 0.6 et 0.8. Ces lignes verticales montrent la concentration autour du point ayant de même TOEFL, cela signifie simplement que plusieurs étudiants ont exactement le même score TOEFL.

## Chance of Admit par expérience de recherche




FIGURE 2.13 – Chance of Admit en fonction de l'expérience de recherche

On note une nette différence entre les deux groupes :

- Les candidats sans recherche (0) ont une médiane d'environ 0.65 avec des valeurs centrées entre 0.55 et 0.7.
- Ceux ayant une expérience de recherche (1) ont une médiane proche de 0.8 et un troisième quartile autour de 0.89.

Cela indique que l'expérience de recherche est clairement liée à une meilleure chance d'admission.

## Nombre de candidats selon l'expérience de recherche




FIGURE 2.14 – Répartition des candidats avec ou sans expérience de recherche

Environ 250 à 300 candidats n'ont pas d'expérience de recherche, tandis que 200 à 250 en ont une. Bien que la majorité ait une expérience, l'écart reste relativement modéré.

«««< HEAD

## 2.6 Conclusion

=====

## 2.7 Conclusion de l'exploration

»»»> 7f1856b (Ajustement du livre)

Cette exploration graphique met en évidence plusieurs éléments :

- Une corrélation positive entre le GRE, TOEFL, CGPA et la chance d'admission ;
- L'influence nette de l'expérience de recherche sur la probabilité d'être admis ;
- Une distribution relativement équilibrée des candidats sur plusieurs variables, bien que certaines zones de concentration soient identifiables.

Ces observations seront utilisées pour guider les choix de modélisation dans les prochaines sections.

# Chapitre 3

## Modélisation

«««< HEAD Ici, on a testé différents algorithmes de classification pour prédire les chances pour un étudiants d'entré dans les écoles aussi dans les universités. On a surtout utilisé : **SVM (SVC)**, **Decision Tree**, **Random Forest**, **Régression logistique** et **K Nearest Neighbours (KNN)**. Pour chaque modèle, on a normalisé les données avec **StandardScaler**.

### 3.1 Évaluation des modèles

Chaque modèle a été entraîné avec 80% des dataset et testé sur les 20% restants du dataset. Pour comparer leurs performances, on s'est basé sur les métriques suivantes :  
===== Nous avons testé différents algorithmes de classification pour prédire les chances pour un étudiant d'entré dans les écoles aussi dans les universités. On a surtout utilisé :

- **SVM (SVC)** ou **Support Vector Classifier** : c'est un algorithme qui cherche à séparer les données en traçant une frontière qui maximise la marge entre les différentes classes.
- **Decision Tree** : construit un arbre de décisions en découpant les données selon les variables les plus discriminantes pour prédire la classe ou la valeur cible.
- **Random Forest** : combine plusieurs arbres de décision entraînés sur des sous-échantillons aléatoires afin d'améliorer la précision et réduire le surapprentissage.
- **Régression logistique** : qui modélise la probabilité qu'une observation appartienne à une classe en utilisant une fonction logistique.
- **K Nearest Neighbours (KNN)** : c'est un algorithme qui classe un nouvel élément en regardant la majorité des classes parmi ses K voisins les plus proches.

Pour chaque modèle, on a normalisé les données avec **StandardScaler** son role est important les features de chaque modèle n'ont pas le meme échelle donc certains peuvent dominer les autres.

### 3.2 Évaluation des modèles

Chaque modèle a été entraîné avec 80% des dataset et testé sur les 20% . Pour comparer leurs performances, on s'est basé sur les métriques suivantes : »»»> 7f1856b (Ajustement du livre)

- **Accuracy** : le taux de bonnes réponses

- **Precision** : la proportion de vrais positifs parmi les prédictions positives
- **Recall** : la capacité à trouver tous les vrais positifs
- **F1-score** : une moyenne entre la précision et le rappel

### 3.3 Résultats obtenus

Voici un tableau qui résume les performances de chaque modèle :

| Modèle                                  | Accuracy | Précision | Rappel | F1-score |
|-----------------------------------------|----------|-----------|--------|----------|
| 7f1856b (Ajustement du livre) heightSVC | 0.90     | 0.94      | 0.91   | 0.92     |
| Arbre de décision                       | 0.76     | 0.82      | 0.82   | 0.82     |
| Forêt aléatoire                         | 0.87     | 0.89      | 0.93   | 0.91     |
| Régression logistique                   | 0.87     | 0.92      | 0.88   | 0.90     |
| KNN                                     | 0.87     | 0.92      | 0.88   | 0.90     |

TABLE 3.1 – Comparaison des performances des différents modèles

### 3.4 Courbes d'apprentissage

Pour mieux comprendre le comportement des modèles, on a tracé des courbes d'apprentissage qui montrent comment les performances évoluent avec la quantité de données :




FIGURE 3.1 – Courbe d'apprentissage pour SVC




FIGURE 3.2 – Courbe d'apprentissage pour Forêt aléatoire




FIGURE 3.3 – Courbe d'apprentissage pour Arbre de décision






FIGURE 3.4 – Courbe d'apprentissage pour Régression logistique




FIGURE 3.5 – Courbe d'apprentissage pour KNN

### 3.5 Analyse des résultats

En regardant les résultats, on peut faire plusieurs constats intéressants :

- Le modèle **SVC** donne les meilleurs résultats globaux avec un F1-score de 0.92

- Les modèles **Forêt aléatoire** et **KNN** ont des performances assez similaires
  - L'**arbre de décision** semble sur-apprendre et a des scores plus bas
  - La **régression logistique** se comporte bien et arrive surtout à généraliser : au lieu de juste mémoriser les données, elle apprend vraiment les relations entre les variables
- «««< HEAD Finalement, même si SVC avait les meilleurs scores, on a choisi la régression logistique pour la suite parce qu'elle est plus stable et plus facile à interpréter. C'est ce modèle qu'on a décidé de sauvegarder pour les prédictions futures. ===== Finalement, même si SVC avait les meilleurs scores, on a choisi la régression logistique pour la suite parce qu'elle est plus stable, c'est à dire moins sensible aux variations du jeu de données et aux valeurs extrêmes, et plus facile à interpréter. C'est ce modèle qu'on a décidé de sauvegarder pour les prédictions futures.
- »»»> 7f1856b (Ajustement du livre)

# Chapitre 4

## Déploiement

Dans ce chapitre, nous vous présentons comment nous avons rendu notre modèle entraîné accessible et utilisable, en mettant en place une interface simple permettant de tester les prédictions de notre modèle.

### 4.1 Test interactif du modèle

Afin de permettre une expérience utilisateur intuitive, nous avons développé un script en Python qui invite à saisir pas à pas les informations nécessaires.

Voici comment cela fonctionne :

- L'utilisateur doit renseigner ces notes académiques comme : le **GRE Score**, le **TOEFL Score**, la **Note de l'université**, la force du **SOP** (Statement of Purpose) et du **LOR** (Letter of Recommendation), le **CGPA** (Grade Point Average cumulé), ainsi que son expérience en **recherche**.
- Si une information n'est pas disponible, alors une valeur par défaut sera attribuée, afin de garantir ainsi le bon fonctionnement du modèle même avec des données manquantes.
- Une fois toutes les entrées collectées, le script affiche clairement le résultat sous la forme :
  - `Candidat probablement admis` en cas de prédiction positive.
  - `Candidat probablement non admis` dans le cas contraire.

### 4.2 Chargement du modèle

«««< HEAD Pour pouvoir réutiliser le modèle entraîné sans avoir à le ré-entraîner, nous avons utilisé la bibliothèque `pickle`. Le modèle est donc sauvegardé dans un fichier `logistic.pkl`, ce qui permet de l'utiliser rapidement et de l'intégrer dans n'importe où par exemple dans le site web, etc. ===== Pour pouvoir réutiliser le modèle entraîné sans avoir à le ré-entraîner, nous avons utilisé la bibliothèque `pickle`. Le modèle est donc sauvegardé dans un fichier `logistic.pkl`, ce qui permet de l'utiliser rapidement et de l'intégrer n'importe où par exemple dans le site web, etc. »»»> 7f1856b (Ajustement du livre)

## 4.3 Exemple d'utilisation

Voici un extrait illustrant la simplicité avec laquelle le modèle peut être chargé et testé :

```
import pickle as pkl
with open('models/logistic.pkl', 'rb') as f:
    model_loaded = pkl.load(f)
test_model_input(model_loaded)
```

Ce prototype nous permet de constituer la première étape essentielle vers un déploiement à plus grande échelle.

# Chapitre 5

## Conclusion

Ce travail de recherche nous a permis d'aboutir à la création et à la validation d'un modèle prédictif dont l'objectif principale est d'évaluer les chances d'admission d'un étudiant, en s'appuyant sur le dataset La méthodologie qu'on a adoptée repose sur ces successions d'étapes clés comme :

- **Préparation des données** : Cette phase préliminaire, bien que souvent sous estimée, s'est avérée déterminant. Elle a inclus le nettoyage des données, leurs exploration approfondie, et la sélection des variables principale pour la prédiction.
- **Modélisation** : Une comparaison approfondie parmi plusieurs algorithmes d'apprentissage supervisé a été réalisée. Nous avons confronté leurs performances comme les performances du SVC, random forest, l'Arbre de Décision, la Régression Logistique et les K Nearest Neighbors, cherchant ainsi à trouver lequel de ces algorithmes est le plus précis pour ainsi pouvoir le prendre.
- **Évaluation** : Au-delà des métriques classiques de performance comme l'exactitude, la précision ou le score F1, nous avons analysé les courbes d'apprentissage pour détecter et comprendre les écueils classiques que sont le surajustement ou le sous-ajustement, garantissant ainsi la robustesse de notre modèle.
- **Déploiement** : Pour concrétiser cette étude, une application interactive a été développée. Elle permet à un utilisateur de saisir ses informations et d'obtenir une estimation personnalisée, matérialisant ainsi l'utilité pratique du modèle.

L'examen méticuleux des performances a révélé que la **Régression Logistique** s'est imposée comme l'approche la plus pertinente pour notre jeu de données. Son excellence ne réside pas dans une complexité algorithmique supérieure, mais plutôt dans son équilibre et sa remarquable capacité à généraliser, évitant ainsi les pièges du surajustement dans lesquels sont tombés certains de ses concurrents. Elle a su capturer avec finesse les relations fondamentales liant les variables explicatives au résultat à prédire.

Enfin, ce mémoire ne se contente pas de présenter un modèle opérationnel ; il ouvre la voie à de multiples prolongements. Le développement d'une interface web intuitive ou la publication sous forme d'API constituent des évolutions naturelles pour étendre la portée de cet outil.

Par ailleurs, cette recherche vient rappeler, s'il le fallait encore, que la performance d'un modèle de machine learning ne naît pas de la sophistication de son algorithme, mais bien de la qualité du travail en amont : la préparation des données et leur analyse critique restent la pierre angulaire de tout projet réussi en science des données.

# Annexes

## Bibliothèques utilisées pour l'EDA

```
import pandas as pd
import matplotlib.pyplot as plt
import numpy as np
import seaborn as sns
```

**Explication :** Les bibliothèques `pandas` sont utilisées pour la manipulation et la visualisation des données, `matplotlib` et `seaborn` pour la création des graphiques, et `numpy` pour les calculs numériques.

## Chargement du dataset

```
df = pd.read_csv('data/Admission_Predict_v2.csv')
```

«««< HEAD **Explication :** La fonction `pd.read_csv` permet de charger le dataset afin de pouvoir l'exploiter pour l'analyse et la modélisation. ===== **Explication :** La fonction `pd.read_csv()` permet de charger le dataset afin de pouvoir l'exploiter pour l'analyse et la modélisation. »»»> 7f1856b (Ajustement du livre)

## Affichage des premières lignes du dataset

```
df.head()
```

|   | Serial No. | GRE Score | TOEFL Score | University Rating | SOP | LOR | CGPA | Research | Chance of Admit | LOR |
|---|------------|-----------|-------------|-------------------|-----|-----|------|----------|-----------------|-----|
| 0 | 1          | 337.0     | 118.0       | 4                 | 4.5 | 4.5 | 9.65 | 1        | 0.92            | NaN |
| 1 | 2          | 324.0     | 107.0       | 4                 | 4.0 | 4.5 | 8.87 | 1        | 0.76            | NaN |
| 2 | 3          | 316.0     | 104.0       | 3                 | 3.0 | 3.5 | 8.00 | 1        | 0.72            | NaN |
| 3 | 4          | 322.0     | 110.0       | 3                 | 3.5 | 2.5 | 8.67 | 1        | 0.80            | NaN |
| 4 | 5          | 314.0     | 103.0       | 2                 | 2.0 | 3.0 | 8.21 | 0        | 0.65            | NaN |

**Explication :** La méthode `df.head()` affiche les cinq premières lignes du dataset pour une visualisation rapide de sa structure.

## Aperçu du type des données

```
df.info()
#GRE : Signifie Graduate Record Examination
#TOEFL : Signifie Test of English as a Foreign Language
#SOP : Signifie Statement of Purpose
#utilisé par les comités d'admission pour évaluer les objectifs académiques
#LOR : Signifie Letter of Recommendation
#utilisée pour juger du sérieux, du potentiel et des qualités personnelles du candidat
#CGPA : Signifie Cumulative Grade Point Average
#utilisé pour évaluer la performance académique globale
#Research : Signifie Expérience de recherche cad activité extra-scolaire
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 550 entries, 0 to 549
Data columns (total 10 columns):
#   Column                Non-Null Count  Dtype
---  -
0   Serial No.            550 non-null   int64
1   GRE Score             550 non-null   float64
2   TOEFL Score           513 non-null   float64
3   University Rating     550 non-null   int64
4   SOP                   513 non-null   float64
5   LOR                   550 non-null   float64
6   CGPA                  550 non-null   float64
7   Research              550 non-null   int64
8   Chance of Admit       550 non-null   float64
9   LOR                   0 non-null     float64
dtypes: float64(7), int64(3)
memory usage: 43.1 KB
```

**Explication :** La méthode `df.info()` fournit un résumé des types de données et du nombre de valeurs non nulles pour chaque colonne.

## Résumé statistique du dataset

```
df.describe()
```

|       | Serial No. | GRE Score  | TOEFL Score | University Rating | SOP        | LOR        | CGPA       | Research   | Chance of Admit | LOR |
|-------|------------|------------|-------------|-------------------|------------|------------|------------|------------|-----------------|-----|
| count | 550.000000 | 550.000000 | 513.000000  | 550.000000        | 513.000000 | 550.000000 | 550.000000 | 550.000000 | 550.000000      | 0.0 |
| mean  | 250.896364 | 316.335651 | 107.204041  | 3.125455          | 3.376218   | 3.484545   | 8.591772   | 0.572727   | 0.721655        | NaN |
| std   | 146.927197 | 12.674963  | 6.434952    | 1.135889          | 0.995978   | 0.925375   | 0.616908   | 0.495133   | 0.142310        | NaN |
| min   | 1.000000   | 277.754368 | 91.916154   | 1.000000          | 1.000000   | 1.000000   | 6.800000   | 0.000000   | 0.340000        | NaN |
| 25%   | 121.250000 | 308.000000 | 102.725335  | 2.000000          | 2.500000   | 3.000000   | 8.131200   | 0.000000   | 0.630000        | NaN |
| 50%   | 251.500000 | 316.000000 | 107.000000  | 3.000000          | 3.500000   | 3.500000   | 8.589128   | 1.000000   | 0.720000        | NaN |
| 75%   | 378.750000 | 325.000000 | 112.000000  | 4.000000          | 4.000000   | 4.000000   | 9.060000   | 1.000000   | 0.830000        | NaN |
| max   | 500.000000 | 353.144823 | 125.588646  | 5.000000          | 5.000000   | 5.000000   | 10.240747  | 1.000000   | 0.970000        | NaN |

**Explication :** La méthode `df.describe()` fournit des statistiques descriptives pour les colonnes numériques, telles que la moyenne, l'écart-type, les valeurs minimales et maximales.

## Suppression des colonnes inutiles

```
df_clean = df.drop(columns=[df.columns[9], df.columns[0]])
```

**Explication :** La colonne `Serial No.` a été supprimée car elle n'est pas pertinente pour l'entraînement du modèle. De même, le doublon de la colonne `LOR` a été retiré.



## Nettoyage des données

```
df_clean.isna().sum()
```

|                   |       |
|-------------------|-------|
| GRE Score         | 0     |
| TOEFL Score       | 37    |
| University Rating | 0     |
| SOP               | 37    |
| LOR               | 0     |
| CGPA              | 0     |
| Research          | 0     |
| Chance of Admit   | 0     |
| dtype:            | int64 |

```
df_clean = df_clean.dropna()
```

**Explication :** Le nombre de valeurs manquantes a été évalué avec `df_clean.isna().sum()`. Les lignes contenant des valeurs manquantes ont ensuite été supprimées à l'aide de `df_clean.dropna()`.

## Visualisation univariée des données

```
df_clean["GRE Score"].hist()
```

```
df_clean["CGPA"].hist()
```

```
df_clean["TOEFL Score"].hist()
```

```
df_clean["University Rating"].hist()
```

```
df_clean["Chance of Admit "].hist()
```

```
df_clean["Research"].value_counts().plot(kind='pie', autopct='%1.1f%%')
```

**Explication :** Ces graphiques présentent la distribution de chaque variable individuelle du dataset.

## Visualisation bivariable des données

```
df_clean.plot.scatter(x='GRE Score', y='Chance of Admit ', colormap='viridis', alpha=0.5)
```

```
df_clean["GRE Score"].corr(df_clean["Chance of Admit "])
```

```
df_clean.plot.scatter(x='CGPA', y='Chance of Admit ', colormap='viridis', alpha=0.6)
```

```
df_clean["CGPA"].corr(df_clean["Chance of Admit "])
```

```
df_clean.plot.scatter(x='TOEFL Score', y='Chance of Admit ', colormap='viridis', alpha=0.5)
```

```
df_clean["TOEFL Score"].corr(df_clean["Chance of Admit "])
```

```
df_clean.boxplot(column='Chance of Admit ', by='Research', figsize=(10, 6))
```

```
df_clean["Research"].corr(df_clean["Chance of Admit "])
```

```
corr_matrix = df_clean.corr(numeric_only=True)
corr_matrix
```

```
# Visualiser la corrélation entre la moyenne générale (CGPA) et la chance d'admission.
plt.scatter(df_clean['CGPA'], df_clean['Admitted'], alpha=0.6, color='green')
plt.title("CGPA vs Admission")
plt.xlabel("CGPA")
plt.ylabel("Admit")
plt.show()
```

```
sns.boxplot(x='University Rating', y='TOEFL Score', data=df_clean)
plt.title("Distribution TOEFL selon University Rating")
plt.show()
```

```
sns.pairplot(df_clean[['GRE Score', 'TOEFL Score', 'CGPA', 'Admitted']].dropna())
plt.suptitle("Relations entre variables clés", y=1.02)
plt.show()
```

**Explication :** Ces graphiques montrent les relations entre deux variables du dataset, permettant d'identifier les corrélations et tendances.

## Variables utilisées pour l'entraînement du modèle

```
● #Les colonnes qu'on utilisera pour entraîner le modèle
features = ['GRE Score', 'TOEFL Score', 'University Rating', 'SOP', 'LOR ', 'CGPA', 'Research']
x = df_clean[features]
y = df_clean['Admitted']
```

## Bibliothèques utilisées pour l'entraînement du modèle

```
from sklearn.svm import SVC
from sklearn.tree import DecisionTreeClassifier
from sklearn.ensemble import RandomForestClassifier
from sklearn.linear_model import LogisticRegression
from sklearn.neighbors import KNeighborsClassifier
from sklearn.preprocessing import StandardScaler
from sklearn.model_selection import train_test_split, learning_curve, cross_val_score
from sklearn.metrics import classification_report, confusion_matrix, accuracy_score
from sklearn.pipeline import Pipeline
```

## Exemple de code utilisé pour l'entraînement du modèle

```

# Pipeline
rfc_pipeline = Pipeline([
    ('scaler', StandardScaler()),
    ('classifier', RandomForestClassifier(random_state=42))
])

# Courbe d'apprentissage
train_sizes, train_scores, val_scores = learning_curve(
    rfc_pipeline,
    X, y,
    train_sizes=np.linspace(0.1, 1.0, 10),
    cv=5,
    scoring='accuracy',
    shuffle=True,
    random_state=42
)

# Moyennes et écarts-types
train_mean = np.mean(train_scores, axis=1)
val_mean = np.mean(val_scores, axis=1)
train_std = np.std(train_scores, axis=1)
val_std = np.std(val_scores, axis=1)

# Affichage 1 : simple
plt.figure(figsize=(10, 5))
plt.plot(train_sizes, train_mean, 'o-', Label="Train Accuracy")
plt.plot(train_sizes, val_mean, 'o-', Label="Validation Accuracy")
plt.title("Learning Curve")
plt.xlabel("Nombre d'échantillons d'entraînement")
plt.ylabel("Accuracy")
plt.legend()
plt.grid(True)
plt.show()

# Affichage 2 : avec bandes d'incertitude
plt.figure(figsize=(10, 6))
plt.plot(train_sizes, train_mean, 'o-', color='blue', Label='Score entraînement')
plt.fill_between(train_sizes, train_mean - train_std, train_mean + train_std, alpha=0.1, color='blue')

plt.plot(train_sizes, val_mean, 'o-', color='green', Label='Score validation')
plt.fill_between(train_sizes, val_mean - val_std, val_mean + val_std, alpha=0.1, color='green')

plt.title('Courbe d'apprentissage')
plt.xlabel('Taille de l\'échantillon d\'entraînement')
plt.ylabel('Exactitude')
plt.legend(loc='best')
plt.grid(True)
plt.tight_layout()
plt.show()

```

## Exemple de code utilisé pour tester le modèle

```
def test_model_input(model):
    print("=== Prédiction d'admission à l'université ===")
    print("Tape 'aucun' si tu n'as jamais passé un test ou fourni un document.\n")

    # GRE Score
    while True:
        gre_input = input("GRE Score (260-340 ou 'aucun') : ").strip().lower()
        if gre_input == 'aucun':
            gre = 300 # valeur par défaut neutre
            print("GRE non fourni. Valeur par défaut utilisée : 300")
            break
        try:
            gre = float(gre_input)
            if 260 <= gre <= 340:
                break
            else:
                print("Valeur hors plage.")
        except ValueError:
            print("Entrée invalide.")

    # TOEFL Score
    while True:
        toefl_input = input("TOEFL Score (0-120 ou 'aucun') : ").strip().lower()
        if toefl_input == 'aucun':
            toefl = 90 # valeur par défaut neutre
            print("TOEFL non fourni. Valeur par défaut utilisée : 90")
            break
        try:
            toefl = float(toefl_input)
            if 0 < toefl <= 120:
                break
            else:
                print("Valeur hors plage.")
        except ValueError:
            print("Entrée invalide.")

    # University Rating
    while True:
        ur_input = input("Note de l'université (1 à 5 ou 'aucun') : ").strip().lower()
        if ur_input == 'aucun':
            ur = 3 # neutre
            print("Note d'université non fournie. Valeur par défaut utilisée : 3")
            break
        try:
            ur = int(ur_input)
            if 1 <= ur <= 5:
                break
            else:
                print("Valeur hors plage.")
        except ValueError:
            print("Entrée invalide.")

    # SOP
    while True:
        sop_input = input("SOP (Lettre de motivation notée de 0.0 à 5.0 ou 'aucun') : ").strip().lower()
        if sop_input == 'aucun':
```

```
    # GRE Score
    while True:
        gre_input = input("GRE Score (260-340 ou 'aucun') : ").strip().lower()
        if gre_input == 'aucun':
            gre = 300 # valeur par défaut neutre
            print("GRE non fourni. Valeur par défaut utilisée : 300")
            break
        try:
            gre = float(gre_input)
            if 260 <= gre <= 340:
                break
            else:
                print("Valeur hors plage.")
        except ValueError:
            print("Entrée invalide.")

    # TOEFL Score
    while True:
        toefl_input = input("TOEFL Score (0-120 ou 'aucun') : ").strip().lower()
        if toefl_input == 'aucun':
            toefl = 90 # valeur par défaut neutre
            print("TOEFL non fourni. Valeur par défaut utilisée : 90")
            break
        try:
            toefl = float(toefl_input)
            if 0 < toefl <= 120:
                break
            else:
                print("Valeur hors plage.")
```

**Explication :** Ces extraits montrent l'évaluation du modèle sur le dataset de test, incluant la prédiction et l'analyse des résultats. «««< HEAD

# bibliographie

Dans cette section, nous listons l'ensemble des sources consultées pour la réalisation de ce travail, principalement des sites web fournissant des données, articles ou documentations pertinentes.

=====



# Bibliographie

»»»> 7f1856b (Ajustement du livre)

1. Dataset principale. *admission\_rate\_er1.csv*. Disponible sur : . Consulté le 25 août 2025.

Dataset test. *gc\_data.csv*. Disponible sur : . Consulté le 20 août 2025.

Dataset test. *Predict students dropout and academic success*. Disponible sur : <https://archive.ics.uci.edu/dataset/697/predict+students+dropout+and+academic+success>. Consulté le 18 août 2025.

Dataset test. *Graduate school admission data*. Disponible sur : [https://figshare.com/articles/dataset/Graduate\\_school\\_admission\\_data/19561582](https://figshare.com/articles/dataset/Graduate_school_admission_data/19561582). Consulté le 22 août 2025.

TheGradCafe. *How to scrape the website of thegradcafe*. Disponible sur : [forum.thegradcafe.com/topic/51483-scraped-admissions-data](https://forum.thegradcafe.com/topic/51483-scraped-admissions-data). Consulté le 21 août 2025.