



INSTITUT NATIONAL SUPERIEUR D'INFORMATIQUE

MÉMOIRE DE PROJET EN VUE DE LA VALIDATION DE LA LICENCE 2

Domaine : Sciences et Technologies

Mention : Informatique

Parcours : Ingénierie en Intelligence Artificielle et Data Science

Par : Monsieur Aritendry RAMAHAFENO et
Monsieur Bernardin RASOLONJANAHARY

Predicton du taux de reussite au concours d'entré école/université

Soutenu le 05 Septembre 2025, devant la commission d'examen composée de :

Président : Docteur RAKOTOMANANJARA David Fitiana

Examineur : Monsieur RASOLOFOMANANA Tolotra Iarivony Nirina

Directeur de mémoire : Docteur RABERARIVONY Andriamahazosoa
Dimbinantenaina

Année universitaire : 2024 – 2025

Introduction Générale

0.1 Contexte

L'entrée à l'université représente un enjeu important pour beaucoup d'étudiants, et les concours d'admission sont souvent une étape décisive. Pouvoir prédire les chances de réussite permet non seulement d'aider les candidats à mieux se préparer, mais aussi d'accompagner les établissements dans leur processus de sélection.

0.2 Problématique

Prédire si un candidat va réussir son concours d'entrée est un vrai défi : les données sont nombreuses par exemple dans Kaggle sur <https://www.kaggle.com/datasets/samsonqian/college-admissions>. Difficile, dans ces conditions, de bâtir un modèle fiable. Il fallait donc trouver une manière efficace de traiter ces informations pour en tirer des prédictions utiles.

0.3 Objectifs

L'objectif de ce projet est de développer un modèle capable d'estimer les probabilités de réussite au concours, en se basant sur des données académiques et des variables pertinentes comme les scores au GRE ou au TOEFL, la moyenne générale (CGPA), ainsi que d'autres critères qualitatifs (SOP, LOR, expérience de recherche). Deux approches complémentaires ont été mises en place :

- la **régression linéaire**, qui fournit une estimation continue du pourcentage de chances d'admission ;
- des modèles de classification supervisée (Logistic Regression, Random Forest, SVC, etc.), qui permettent de donner une décision binaire (admis / non admis).

0.4 Démarche suivie

Pour y parvenir, nous avons commencé par rassembler plusieurs jeux de données, puis nous avons choisi le plus complet et le plus fiable, correspondant le mieux à notre sujet. Ensuite, les données ont été nettoyées et préparées, avant une phase d'exploration pour mieux comprendre leur contenu.

Plusieurs algorithmes de machine learning ont été testés et comparés pour sélectionner celui qui donnait les meilleurs résultats :

- Régression Logistique : 87%

- SVC : 90%
- Decision Tree : 76%
- Random Forest : 87%
- K-Nearest Neighbors : 89%

La **régression linéaire**, quant à elle, a été utilisée en parallèle pour fournir une estimation en pourcentage, complétant ainsi les résultats issus de la classification binaire.

0.5 Structure du rapport

Ce mémoire est organisé en quatre parties :

- La première partie présente la collecte et le prétraitement des données.
- La deuxième détaille la modélisation et l'évaluation des différents algorithmes.
- La troisième analyse les résultats et les performances du modèle retenu.
- Enfin, la dernière partie discute des limitations et propose des pistes d'amélioration pour aller plus loin.

Présentation de l'INSI

1. Information d'ordre général

INSI (Institut National Supérieur d'Informatique) est un institut universitaire situé à Antananarivo, spécialisé dans le domaine de l'informatique. Il accueille principalement des bacheliers ayant choisi cette filière, mais reste également ouvert à toute personne manifestant un intérêt particulier pour les métiers du numérique, à travers son centre de formation professionnelle.

L'établissement a été fondé le 17 août 2021 et son siège se trouve à Ankazotokana Ambanidia, Lot VF 32 Ter.

Pour tout renseignement, vous pouvez nous contacter par email à contact@insi.mg ou visiter notre site web : www.insi.mg

INSI University bénéficie du soutien d'entreprises partenaires, dont Ilo Madagascar SARLU et Data Pulse Center, qui sont également à l'origine de sa création.

2. Missions et historiques

INSI University a été fondée le 17 août 2021 à Antananarivo, dans un contexte marqué par une forte demande de compétences dans le domaine de l'informatique et des technologies numériques,

Créé à l'initiative de Ilo Madagascar SARLU et Data Pulse Center, l'Institut a vu le jour avec pour ambition de former une nouvelle génération de professionnels qualifiés, capables de répondre aux besoins du marché local et international.

Depuis sa création, INSI ne cesse d'évoluer en adaptant ses formations aux enjeux technologiques actuels, tout en favorisant un apprentissage pratique, orienté vers les réalités du monde professionnel.

La mission principale de l'INSI est de former des experts compétents, éthiques et innovants dans le domaine de l'informatique, capables de contribuer activement au développement économique et numérique de Madagascar.

L'Institut s'engage à :

- Offrir des formations de qualité, à jour des évolutions technologiques,
- Favoriser l'insertion professionnelle de ses apprenants,
- Créer un lien fort entre la formation académique et les besoins réels des entreprises,
- Encourager l'entrepreneuriat et l'innovation technologique,
- Contribuer à la démocratisation de l'accès au savoir numérique.

1. Organigramme de l'INSI

L'organigramme ci-dessous présente la structure organisationnelle de l'INSI, mettant en évidence les différentes fonctions et responsabilités au sein de l'institut, ainsi que les liens hiérarchiques entre les divers services.



ORGANIGRAMME INSI




Figure 1 : Organigramme de l'INSI

L'organigramme de l'INSI, en partenariat avec le Collège de Paris, est structuré autour d'une direction générale incarnée par le Président Directeur Général. Ce dernier assure la coordination de trois pôles principaux : la Direction Administrative et Financière, la Direction des Études, et le service des Relations Internationales et Mobilités.

Le Président Directeur Général assure la direction stratégique de l'institut. Il supervise l'ensemble des activités pédagogiques, administratives et de développement.

Il veille à la qualité de l'enseignement, à la bonne gestion des ressources humaines et matérielles, et représente l'établissement auprès des partenaires et autorités.

La Direction Administrative et Financière est chargée de la gestion des affaires internes, notamment à travers deux services essentiels : le service des scolarités, qui s'occupe des dossiers étudiants, inscriptions et suivi académique, et les services supports et stratégiques, qui assurent un appui logistique, administratif et technologique à l'ensemble de l'institut.

Le pôle des Relations Internationales et Mobilités gère les échanges académiques avec l'étranger ainsi que les projets de mobilité étudiante ou enseignante.

La Direction des Études supervise quant à elle l'ensemble des programmes pédagogiques et le corps enseignant. Elle travaille en étroite collaboration avec un Responsable Parcours, qui coordonne les différentes spécialisations proposées. Cette direction intègre également une cellule dédiée à la formation professionnelle et à la certification, en charge

des dispositifs de validation des compétences, des certifications professionnelles et des parcours de formation continue. Il comprend également le Département alternance et emplois, responsable du suivi des étudiants en contrat d’alternance, des stages professionnels, et de l’insertion professionnelle.

Sous la partie Responsable Parcours, plusieurs responsables pédagogiques gèrent les différentes filières de formation : le parcours tronc commun, qui regroupe les matières fondamentales partagées par tous les étudiants en début de cycle ; le parcours ARSB & IC ; le parcours GL & MSI ; et enfin le parcours IAD & I2AD.

D’autres structures, bien que non représentées sur cet organigramme, contribuent également de manière significative à la mission de l’INSI.

Le Conseil de l’École, Il regroupe des membres de l’équipe pédagogique et administrative. Il joue un rôle consultatif ou décisionnel sur les questions académiques : validation des programmes, suivi des résultats, discipline, méthodologie, etc.

Le responsable de la formation en ligne, Il conçoit et supervise les dispositifs d’apprentissage à distance. Il s’assure que les contenus en ligne sont accessibles, interactifs et conformes aux standards pédagogiques, tout en accompagnant enseignants et étudiants dans leur utilisation.

L’Association et Clubs étudiants, encadre et soutient les initiatives étudiantes, les clubs thématiques (informatique, innovation, sport, culture, etc.), et les événements organisés dans le cadre de la vie étudiante. Cela favorise l’engagement, le développement personnel et les compétences transversales des étudiants.

Cette structure témoigne d’une organisation à la fois pédagogique, administrative et tournée vers l’international et l’employabilité, assurant une formation complète et professionnalisante aux étudiants.

2. Domaine de spécialisation

INSI University propose des parcours académiques professionnalisants dans le domaine de l’informatique et des technologies numériques, articulés autour de licences professionnelles, de masters spécialisés, formations professionnelles continues et d’opportunités de mobilité internationale.

a) Licences professionnelles

Les programmes de licence offrent une formation de base solide, axée sur la pratique, et préparant à une insertion rapide dans le monde professionnel :

GL (Génie Logiciel) : Conception, développement et maintenance d’applications logicielles.

ARSB (Administration Réseaux et Systèmes et Base de données) : Gestion d’infrastructures informatiques, réseaux, serveurs et systèmes.

IAD (Intelligence Artificielle et Data Science) : Introduction aux algorithmes d’IA, au traitement de données et à l’apprentissage automatique.

b) Masters professionnels

Les masters permettent d’approfondir les compétences techniques et managériales, en lien étroit avec les évolutions du secteur :

MSI (Management des Systèmes d’Information) : Pilotage de projets numériques, gouvernance des SI.

IC (Infrastructures et Cybersécurité) : Sécurisation des systèmes, audit, réseaux avancés.

IAD (Intelligence Artificielle, Analyse de Données et Automatisation) : Applications avancées de l’IA, automatisation des processus et science des données.

c) Formations professionnelles

INSI University propose également des formations professionnelles continues, spécifiquement conçues pour les professionnels déjà en poste souhaitant approfondir leurs compétences ou se spécialiser dans l'un des domaines proposés.

Ces formations sont adaptées aux contraintes des professionnels (horaires flexibles, modules pratiques) et visent à renforcer leur employabilité ou à accompagner leur évolution de carrière.

d) Mobilité internationale & double diplôme

Dans une optique d'ouverture et de reconnaissance internationale, INSI propose à ses étudiants des opportunités de mobilité académique et de double diplôme, à partir de la deuxième année (L2).

- **Format hybride** : 6 mois de formation à Madagascar + 6 mois à l'étranger selon le parcours choisi.
- **Double diplôme en L3 ou M2** : En partenariat avec des institutions internationales telles que :
 - Collège de Paris (France)
 - Keyce Informatique (France)
 - Eskills (Québec, Canada)

Conditions d'éligibilité

- Niveau DALF C1 en français pour la mobilité vers des pays francophones.
- Niveau B2 ou C1 en anglais pour les destinations anglophones.

1. Architectures des formations pédagogiques

Le recrutement des étudiants à l'INSI s'effectue exclusivement par sélection de dossiers pour l'entrée en première année de Licence (L1), et par voie de concours pour l'admission en Master 1,

Au sein de l'INSI, une seule mention est proposée : Informatique, déclinée en trois parcours distincts aux niveaux Licence et Master :

Tableau 1 : Les parcours en Licence et Master

||@ >p() * 0.5021 >p() * 0.4979@

() **Licence**

Master

() Génie Logiciel (GL) Management des Systèmes d'Information (MSI)

Administration Réseaux, Systèmes et Bases de données (ARSB) Infrastructures et Cybersécurité (IC)

Intelligence Artificielle et Data Science (IAD) Intelligence Artificielle, Analyse de Données et Automatisation (I2AD)

()

L'architecture des études à trois niveaux conformément au système LMD (Licence Master et Doctorat) permet les comparaisons et les équivalences académiques des diplômes au niveau international.

L = Licence (Bac + 3) = L1, L2, L3 = 6 semestres S1 à S6

M = Master (Bac + 5) = M1, M2 = 4 **semestres S7 à S10**

Le diplôme de licence est obtenu en 3 années des études après Baccalauréat. Et le

diplôme de Master est obtenu en 2 ans après obtenu du diplôme de LICENCE.

Le MASTER PROFESSIONNEL est un diplôme destiné à la recherche emploi au terme

des études.

Spécificités pédagogiques

— École d'alternance dès la L2 S4

Alternance cours/entreprise pour une meilleure insertion

— Écoles connectées & e-learning

Plateforme numérique de formation, cloud intégré, Google Workspace

Cours accessibles en ligne selon les parcours

— Pédagogie active & par projets

Hackathons, soutenances exposées, projets réels en entreprise

1. Relations de l'INSI avec les entreprises et les organismes

L'Institut National Supérieur en Informatique (INSI) entretient des liens étroits avec le monde professionnel. L'INSI collabore activement avec de nombreux organismes publics, semi-publics et privés, tant au niveau national qu'international. Cette collaboration se traduit concrètement par l'organisation régulière de stages obligatoires pour les étudiants, favorisant leur immersion professionnelle et leur employabilité.

Parmi les entreprises et institutions partenaires accueillant nos étudiants en stage chaque année, on peut citer : Data Pulse Center, RELIA Consulting, Code Talent, Bo-casay, Minimad, Smartone AI, NOVITY, Eclasia Madagascar, VISEO Groupe, Océane Trade, ACCES Banque, ...

En plus des stages, l'INSI organise régulièrement des visites pédagogiques, des rencontres métiers et des projets collaboratifs avec plusieurs entreprises du secteur technologique et numérique. Ces activités permettent aux étudiants de mieux comprendre les réalités du terrain, d'échanger avec des professionnels et de s'ouvrir à l'environnement entrepreneurial.

Parmi les entreprises ayant accueilli ces initiatives : NOVITY, YAS Madagascar, Smartone AI, Eclasia Madagascar, et d'autres acteurs majeurs du numérique à Madagascar.

Cette dynamique de partenariat permanent constitue un pilier de la pédagogie à l'INSI, en lien avec son objectif de former des professionnels compétents, opérationnels et ancrés dans les besoins du marché.

2. Partenariat au niveau international

L'INSI s'est inscrit dans une dynamique d'ouverture à l'international grâce à son partenaire fondateur, ILO Madagascar, représentant de l'Organisation Internationale du Travail. Cette orientation se renforce aujourd'hui à travers des partenariats stratégiques avec des institutions académiques et des entreprises internationales, permettant à l'Institut de proposer une formation alignée sur les standards mondiaux.

L'INSI bénéficie actuellement de programmes de co-diplomation et de double diplôme en collaboration avec plusieurs établissements internationaux de renom, tels que :

— Collège de Paris International

— Keyce Informatique (France)

— Eskills Academy (Québec, Canada)

— École Supérieure Polytechnique d'Antsiranana (ESPA) – pour une synergie régionale renforcée.

Ces partenariats permettent non seulement d'enrichir l'offre pédagogique, mais aussi d'ouvrir des perspectives de mobilité académique et professionnelle aux étudiants, en leur offrant une reconnaissance de leurs compétences à l'échelle internationale.

Par ailleurs, à travers les stages annuels et projets pédagogiques, l'INSI collabore également avec des entreprises à dimension régionale ou mondiale, telles que :

- **WISEO Groupe**
- **Eclosia Madagascar** (Groupe mauricien)
- **Smartone AI**
- **NOVITY**, entre autres.

Ces relations actives témoignent de l'ancrage de l'INSI dans un écosystème global, plaçant l'Institut comme un acteur majeur de la formation en informatique à Madagascar, tourné vers l'innovation et les exigences du marché international.

1. Parcours professionnels des diplômés

Les diplômés de la Licence en Informatique de l'INSI disposent d'un socle solide de compétences en programmation, systèmes, réseaux, bases de données et développement logiciel. Cette polyvalence leur permet d'intégrer directement le marché du travail ou de poursuivre en Master. À ce niveau, ils peuvent exercer en tant que :

- **Technicien système et réseau**
- **Développeur web / mobile (front-end ou back-end)**
- **Administrateur systèmes junior**
- **Technicien support IT**
- **Intégrateur / testeur logiciel**
- **Assistant en sécurité informatique**
- **Assistant en projets d'IA ou de data (selon profil)**

Les stages annuels en entreprise leur offrent une première expérience professionnelle valorisante dans des structures variées : entreprises technologiques, banques, administrations, startups, ONG, etc.

La formation de Master proposée à l'INSI, grâce à ses parcours spécialisés, forme des professionnels capables d'intervenir sur des projets complexes, innovants et à dimension stratégique. Les débouchés varient selon la spécialisation choisie :

Parcours Ingénierie logicielle, réseaux et systèmes :

- **Ingénieur en développement logiciel / full-stack**
- **Architecte logiciel**
- **Ingénieur systèmes et réseaux**
- **Administrateur cloud / DevOps**
- **Chef de projet informatique**

Parcours Cybersécurité :

- **Expert en sécurité des systèmes d'information**
- **Analyste SOC / CERT**
- **Auditeur en cybersécurité**
- **Responsable de la sécurité IT (RSSI)**

Parcours Intelligence Artificielle et Data :

- **Data Scientist**
- **Data Analyst**

- **Ingénieur en Intelligence Artificielle**
- **Machine Learning Engineer**
- **Développeur d'applications intelligentes**
- **Consultant en IA**
- **Spécialiste en traitement automatique du langage naturel (TALN)**
- **Spécialiste en vision par ordinateur (Computer Vision)**

Grâce aux partenariats internationaux et aux projets en entreprise, les diplômés du Master peuvent également prétendre à des postes dans des structures multinationales, ou poursuivre une carrière académique et de recherche (doctorat, enseignement supérieur).

1. Ressources humaines

L'INSI s'appuie sur une équipe pédagogique et administrative compétente, dynamique et engagée dans la réussite de ses étudiants. Ses ressources humaines se répartissent comme suit :

Président Directeur de l'INSI : Dr RAMASONDRANO Andriamanjaka
 Responsable parcours ARSB & IC : Mr RATIANARISON Hery Mampionona
 Responsable parcours tronc commun : Dr RAKOTONDRAMANANA R, Sitraka
 Responsable parcours GL & MSI : Mr ANDRIAMIADANA TANTELY ANTOINE
 Responsable parcours IAD & I2AD : par intérim PDG
 Nombres des enseignants : 40
 Nombres des personnels administratives : 04
 Personnels d'appui : 6

Remerciements

D’abord, on veut vraiment dire merci à Dieu qui nous a accompagnés pendant tout ce projet de fin d’études. Sans Sa grâce, on aurait pas eu la force ni le courage d’aller au bout.

On tient aussi à remercier le Dr RABERARIVONY Andriamahazosoa Dimbinantenaina qui nous a supervisés. Ses conseils et sa disponibilité ont été super précieux pour nous, surtout quand on bloquait sur certains points.

Un grand merci aussi à tous les profs du département d’Informatique de l’INSI. Les cours qu’on a eus pendant les deux semestres nous ont vraiment préparés pour ce projet.

Et pour finir, merci du fond du cœur à nos familles. Leur soutien et leurs encouragements ont été super importants pour nous, surtout dans les moments un peu difficiles.

Résumé

Dans projet de fin d'études, on s'est penché sur la prédiction des chances de réussite aux concours d'entrée à l'université. On est parti d'un jeu de données avec différentes variables académiques - les scores GRE et TOEFL, la moyenne générale CGPA, et quelques autres critères qui peuvent jouer.

Le travail consiste d'abord à nettoyer et préparer ces données, puis à tester plusieurs approches de modélisation. On a opté pour une forêt aléatoire (Random Forest) qui nous a donné le meilleur résultat, avec la précision de 90%.

Abstract

This final year project tackles the prediction of success rates in university entrance exams. We worked with a dataset containing various academic indicators including GRE and TOEFL scores, CGPA, and other relevant factors that might influence admission chances.

The work involved cleaning and preparing the data, then experimenting with different modeling approaches. We ultimately selected a Random Forest classifier which showed the best performance in predicting candidate admission with an accuracy of 90%.

Chapitre 1

Exploration des données

1.1 Introduction

La visualisation des données constitue une étape cruciale dans l'analyse exploratoire. Elle permet de :

- comprendre la distribution des variables,
- détecter des tendances ou des regroupements,
- observer les relations entre variables explicatives et la variable cible (*Chance of Admit*),
- orienter les choix de modélisation futurs.

Nous distinguons ici deux types d'analyse : univariée (étude d'une seule variable) et bivariée (étude de la relation entre deux variables).

1.1.1 Chargement du jeu de données

Le jeu de données a été chargé au format .CSV à l'aide de la bibliothèque python pandas :

```
import pandas as pd
df = pd.read_csv("admission_data.csv")
```

La commande `df.info()` permet de voir une partie des colonnes, de leurs types et du nombre de valeurs non nulles. On compte 9 colonnes et 550 lignes.

1.1.2 Aperçu des données du dataset principale

- Le jeu de données contient des variables quantitatives comme (*GRE Score*, *TOEFL Score*, *CGPA*, *Chance of Admit*) et discrètes (*University Rating*, *SOP*, *LOR*, *Research*).
- Ici *Chance of Admit* est la variable cible. Elle indique la probabilité d'admission. Source du dataset : <https://dr-raz.org/statistical-literacy-csv-data>

Le jeu de données principale que nous avons utilisé contient des variables quantitatives comme (*GRE Score*, *TOEFL Score*, *CGPA*, *Chance of Admit*) et discrètes (*University Rating*, *SOP*, *LOR*, *Research*).

Ici *Chance of Admit* est la variable cible. Elle indique la probabilité d'admission. Source du dataset : <https://dr-raz.org/statistical-literacy-csv-data>

On a aussi eu des jeux de données secondaires qu'on a scrapé comme celle de chez <https://www.thegradcafe.com/survey/>, des jeux de données de chez kaggle aussi <https://www.kaggle.com/datasets/nasirayub2/australian-student-performancedata-aspd24>

1.1.3 Traitement des valeurs manquantes

Des valeurs manquantes ont été détectées dans deux colonnes :

- **TOEFL Score**
- **SOP (Statement of Purpose)**

Ces deux colonnes présentaient chacune 37 valeurs manquantes.

La stratégie choisie a été de supprimer toutes les lignes contenant au moins une valeur manquante :

```
df_clean = df.dropna()
```

Puis on a fait une vérification pour s'il n'y a plus de variable manquantes dans le dataset

```
df_clean.isnull().sum()
```

Résultat : toutes les valeurs manquantes ont été supprimées. Le jeu de données final contient 513 lignes.

1.1.4 Détection de doublons

Pour vérifier la présence de doublons, j'ai utilisé la commande suivante :

```
df_clean.duplicated().sum()
```

Résultat : aucune ligne dupliquée n'a été détectée.


1.1.5 Étude des valeurs aberrantes

Des diagrammes en boîte (*boxplots*) ont été tracés pour les variables numériques afin de visualiser les potentiels outliers. Bien que certains points soient situés à l'extérieur du graphe de boîtes à moustache, aucun n'a été jugé significativement aberrant ou incohérent (par exemple, un CGPA supérieur à 10 ou un score GRE supérieur à 340). Aucun traitement particulier n'a été effectué à ce niveau.

1.1.6 Étude des corrélations

Une matrice de corrélation a été générée pour évaluer les relations entre les variables :

```
corr_matrix = df_clean.corr()
```



Les coefficients de corrélation les plus élevés avec la variable cible *Chance of Admit* sont :

Critère	Valeur
CGPA	0.87
GRE Score	0.82
TOEFL Score	0.79
Research	0.55

On voit que les performances académiques (CGPA, GRE, TOEFL) et l'expérience de recherche sont fortement corrélés aux chances d'admission.

1.1.7 Conclusion de l'exploration

L'analyse exploratoire a permis de :

- Nettoyer le jeu de données (suppression des lignes incomplètes),
- Confirmer l'absence de doublons,
- Identifier les variables les plus corrélées à la cible,
- Préparer les données pour les étapes de visualisation et de modélisation.

1.2 Présentation des dataset secondaires

Nom du Dataset : gc_data.csv

Les colonnes du le dataset :


- School, Program, Result, Result_Date, GPA,

— Verbal_GRE, Quant_GRE, Writing_GRE, Subject_GRE,
 — Status, Submit_Date, Degree_Type

Aperçu des 5 premières lignes du dataset :

	Verbal_GRE	Quant_GRE	Writing_GRE	GPA	Admitted
1	153.0	168.0	3.0	3.65	1
2	166.0	163.0	4.0	3.89	1
4	162.0	169.0	3.5	3.84	1
6	164.0	164.0	3.5	4.00	1
11	156.0	163.0	4.5	3.60	1

FIGURE 1.1 – Aperçu des 5 premières lignes du dataset



Les variables principales du dataset secondaire gc_data.csv(Verbal_GRE, Quant_GRE, Writing_GRE et GPA) sont faiblement corrélées à la variable cible(Admitted). Cette faiblesse de corrélation est peut être due à une falsification de données.

Choix des variables explicatives (X) :

Nous avons sélectionné les variables suivantes comme variables explicatives :

- Verbal_GRE
- Quant_GRE
- Writing_GRE
- GPA
- Admitted

Variable cible (Y) :

La variable cible est **Admitted**. Cette variable correspond à notre objectif d'étude, car elle représente la classification binaire 1 pour admit et 0 pour le contraire qui sert à prédire si l'étudiant peut être passer ou pas.

Nom du Dataset : Australian_Student_PerformanceData (ASPD24).csv

Australian dataset c'est une donnée de performance des étudiants de l'Australie.

Les colonnes dans le dataset :

51 colonnes y compris :

- GPA
- High School GPA
- Entrance Exam Score
- Attendance
- Family Income
- Parental Education
- Health
- Mental Health
- Exam Scores
- Final Exam Scores
- Gender
- Hours of Study per Week
- Performance ou P_encoded après l'encodage du variable cible

Aperçu des 5 premières lignes du dataset :

	Student ID	University ID	University Name	Age	Gender	Major	Year of Study	GPA	High School GPA	Entrance Exam Score	...
0	1	86	University C	25	F	EE	1	2.06	3.50	60	...
1	2	17	University A	26	F	ME	4	2.12	3.46	52	...
2	3	52	University C	20	M	CS	4	2.72	3.33	94	...
3	4	91	University A	25	M	ME	1	3.05	3.54	65	...
4	5	33	University C	22	F	CE	3	1.86	3.35	51	...

FIGURE 1.2 – Les 5 premières lignes du dataset

Les variables independants suivants : GPA, High School GPA, Entrance Exam Score, Attendance, Family Income, Parental Education, Health, Mental Health, Exam Scores




FIGURE 1.3

sont incorrélées aux variable cible qui est Performance ou P_encoded comme montrer la figure ci-dessous.

Choix des variables explicatives (X) :

Parmi les variables ci-dessus nous avons sélectionné les variables suivantes comme variables explicatives :

- GPA
- Final Exam Scores
- Gender
- Parental Education Level
- Family Income
- Hours of Study per Week

Variable cible (Y) :

La variable cible est **Performance** ou encore **P_encoded**. Cette variable correspond mais pas à 100% peut être à 70% sur notre objectif d'étude, car elle représente la performance des étudiants mais pas le classifie.

1.3 Visualisation des données du dataset principale

1.4 Analyse univariée

1.4.1 GRE Score

Pour pouvoir analyser la distribution du variable GRE Score, on a utilisé la visualisation par histogramme pour mieux voir sa distribution comme on voit sur la figure 1.4




FIGURE 1.4 – Distribution du GRE Score

La majorité des scores GRE se situe entre 300 et 335. Cela montre une répartition relativement homogène avec une concentration autour de scores élevés, ce qui peut refléter un ensemble de candidats compétitifs.

1.4.2 CGPA

Pour pouvoir voir la distribution du variable CGPA, on a utilisé la visualisation par histogramme comme on voit sur la figure 1.5




FIGURE 1.5 – Distribution du CGPA

On observe une forte concentration des CGPA entre 8.0 et 9.5. Très peu de candidats ont un CGPA inférieur à 7.5. Entre 9.5 et 10, on note aussi une densité significative, indiquant que de nombreux candidats obtiennent des résultats académiques très solides.

1.4.3 TOEFL Score

Pour pouvoir analyser la distribution du variable TOEFL Score, on a utilisé la visualisation par histogramme pour mieux voir sa distribution comme on peut constater sur la figure 1.6.




FIGURE 1.6 – Distribution du TOEFL score

Les scores TOEFL se concentrent principalement entre 100 et 110, ce qui est typique d'étudiants internationaux préparés. Quelques candidats atteignent même des scores supérieurs à 115.

1.4.4 University Rating

Pour pouvoir analyser la distribution du variable University Rating, on a encore utilisé la visualisation par histogramme pour mieux voir sa distribution comme on voit sur la figure 1.7.




FIGURE 1.7 – Distribution de l'évaluation des universités

Les notes d'université sont principalement réparties entre 2 et 4. Très peu de candidats proviennent d'universités notées 1 ou 5, ce qui suggère une tendance vers des établissements modérément bien classés.

1.4.5 Research

Pour mieux voir la répartition des étudiants qui ont fait de recherche et ce qui n'ont pas fait en pourcentage, on utilise un diagramme circulaire comme on voit sur la figure 1.8.




FIGURE 1.8 – Répartition des candidats selon l'expérience de recherche

57.1% des candidats ont une expérience de recherche contre 42.9% qui n'en ont pas. Cela souligne que l'expérience de recherche est un critère courant parmi les postulants, possiblement lié à de meilleures chances d'admission.

1.4.6 Chance of Admit

Ici, on a encore utilisé la visualisation par histogramme pour mieux voir sa distribution comme on peut voir sur la figure 1.9.




FIGURE 1.9 – Distribution de la probabilité d'admission

La majorité des valeurs de *Chance of Admit* se situe entre 0.6 et 0.8, indiquant une tendance à des profils relativement compétitifs. Une deuxième concentration apparaît entre 0.8 et 0.9, ce qui montre qu'une part non négligeable des candidats a un fort potentiel d'admission.

1.5 Analyse bivariée

1.5.1 GRE Score vs Chance of Admit

Pour mieux analyser la relation entre la variable GRE Score et Chance of Admit, on a utilisé la visualisation par nuage de point comme on peut le voir sur la figure 1.10.




FIGURE 1.10 – Relation entre GRE Score et Chance of Admit

La relation est globalement croissante : les candidats ayant un GRE supérieur à 320 ont davantage de chances d'admission. La concentration est maximale pour des GRE compris entre 300 et 330 et des probabilités d'admission entre 0.6 et 0.8.

1.5.2 CGPA vs Chance of Admit

Pour mieux analyser la relation entre la variable CGPA et Chance of Admit, on a utilisé la visualisation par nuage de point comme on peut le voir sur la figure 1.11.




FIGURE 1.11 – Relation entre CGPA et Chance of Admit

Une forte corrélation est visible : plus le CGPA est élevé, plus la probabilité d'admission augmente. L'essentiel des données est concentré entre un CGPA de 8 à 9 et un taux d'admission de 0.6 à 0.8.

1.5.3 TOEFL Score vs Chance of Admit

Pour mieux analyser la relation entre la variable TOEFL Score et Chance of Admit, on a utilisé la visualisation par nuage de point comme on peut le voir sur la figure 1.12.




FIGURE 1.12 – Relation entre TOEFL Score et Chance of Admit

La tendance est similaire : les meilleurs scores TOEFL correspondent à des probabilités d'admission plus élevées. La zone la plus dense concerne des scores TOEFL entre 100 et 110, avec des taux d'admission entre 0.6 et 0.8. Ces lignes verticales montrent la concentration autour du point ayant de même TOEFL, cela signifie simplement que plusieurs étudiants ont exactement le même score TOEFL.

1.5.4 Chance of Admit par expérience de recherche

Pour mieux analyser la relation Chance of Admit et expérience de recherche, on a utilisé la visualisation par boîte à moustaches car on peut voir la résumé de la distribution, la médiane et les valeurs extrêmes comme on peut voir 1.13.




FIGURE 1.13 – Chance of Admit en fonction de l'expérience de recherche

On note une nette différence entre les deux groupes :

- Les candidats sans recherche (0) ont une médiane d'environ 0.65 avec des valeurs centrées entre 0.55 et 0.7.
- Ceux ayant une expérience de recherche (1) ont une médiane proche de 0.8 et un troisième quartile autour de 0.89.

Cela indique que l'expérience de recherche est clairement liée à une meilleure chance d'admission.

1.5.5 Distribution du TOEFL selon University rating

Nous allons voir ci dessous pourquoi le niveau d'anglais pourrais influencer notre chance d'intégrer une université




FIGURE 1.14 – Distribution du TOEFL selon l'university

ce graphique montre que les universités les mieux classées (ratings 4 et 5) ont tendance à exiger et à recevoir des candidats avec des scores au TOEFL considérablement plus élevés, ce qui suggère une forte corrélation positive entre le score TOEFL et le classement de l'université.

1.5.6 Nombre de candidats selon l'expérience de recherche

Ici, on a encore utilisé la visualisation par histogramme pour mieux voir la distribution des nombres des candidats selon l'expérience de recherche comme on peut voir sur la f 1.15.




FIGURE 1.15 – Répartition des candidats avec ou sans expérience de recherche

Environ 250 à 300 candidats n’ont pas d’expérience de recherche, tandis que 200 à 250 en ont une. Bien que la majorité ait une expérience, l’écart reste relativement modéré.

1.6 Conclusion de l’exploration

Cette exploration graphique met en évidence plusieurs éléments :

- Une corrélation positive entre le GRE, TOEFL, CGPA et la chance d’admission ;
- L’influence nette de l’expérience de recherche sur la probabilité d’être admis ;
- Une distribution relativement équilibrée des candidats sur plusieurs variables, bien que certaines zones de concentration soient identifiables.

Ces observations seront utilisées pour guider les choix de modélisation dans les prochaines sections.

Chapitre 2

Modélisation

Nous avons testé différents algorithmes de classification pour prédire les chances pour un étudiant d'entrer dans les écoles et universités. Avant de présenter les modèles de classification, nous introduisons d'abord la **prédiction en pourcentage** avec la régression linéaire.

2.1 Prédiction en pourcentage avec Régression linéaire

En complément de la classification binaire, nous avons utilisé la **régression linéaire** pour prédire la *probabilité d'admission* en pourcentage.

Cette approche permet de fournir non seulement si un candidat est admis ou non, mais aussi une estimation numérique de ses chances. Pour ce modèle, nous avons utilisé les variables explicatives : GRE Score, TOEFL Score, University Rating, SOP, LOR, CGPA et Research, avec pour variable cible Chance of Admit.

Le modèle prédit ainsi un pourcentage compris entre 0 et 1.

2.2 Autres modèles de classification

On a ensuite évalué différents algorithmes de classification pour confirmer et comparer les performances :

- **SVM (SVC) ou Support Vector Classifier** : c'est un algorithme qui cherche à séparer les données en traçant une frontière qui maximise la marge entre les différentes classes.
- **Decision Tree** : construit un arbre de décisions en découpant les données selon les variables les plus discriminantes pour prédire la classe ou la valeur cible.
- **Random Forest** : combine plusieurs arbres de décision entraînés sur des sous-échantillons aléatoires afin d'améliorer la précision et réduire le surapprentissage.
- **Régression logistique** : qui modélise la probabilité qu'une observation appartienne à une classe en utilisant une fonction logistique.
- **K Nearest Neighbours (KNN)** : c'est un algorithme qui classe un nouvel élément en regardant la majorité des classes parmi ses K voisins les plus proches.

Pour chaque modèle, on a normalisé les données avec **StandardScaler**, son rôle est important car les features de chaque modèle n'ont pas la même échelle donc certains peuvent dominer les autres.

2.3 Évaluation des modèles

Chaque modèle a été entraîné avec 80% des dataset et testé sur les 20% restants. Pour comparer leurs performances, on s'est basé sur les métriques suivantes :

- **Accuracy** : le taux de bonnes réponses
- **Precision** : la proportion de vrais positifs parmi les prédictions positives
- **Recall** : la capacité à trouver tous les vrais positifs
- **F1-score** : une moyenne entre la précision et le rappel

2.3.1 SVC

```
Model: SVC
Confusion Matrix:
[[30  4]
 [ 6 61]]
Classification Report:
```

	precision	recall	f1-score	support
0	0.83	0.88	0.86	34
1	0.94	0.91	0.92	67
accuracy			0.90	101
macro avg	0.89	0.90	0.89	101
weighted avg	0.90	0.90	0.90	101

```
Accuracy: 0.900990099009901
```

La matrice de confusion, représentée par $\begin{bmatrix} 30 & 4 \\ 6 & 61 \end{bmatrix}$, est le fondement de cette évaluation. Elle se lit comme suit :

- **Vrais négatifs (TN)** : Le modèle a correctement prédit 30 cas négatifs.
- **Faux positifs (FP)** : Le modèle a incorrectement prédit 4 cas positifs.
- **Faux négatifs (FN)** : Le modèle a incorrectement prédit 6 cas négatifs.
- **Vrais positifs (TP)** : Le modèle a correctement prédit 61 cas positifs.

Voici un résumé de la classification :

- **Accuracy** : Avec un score global de 0.90, le modèle a bien prédit 90% des cas. Il a fait 91 prédictions justes sur 101 au total.
- **Précision** : Pour la classe 1, la précision est de 0.94, ce qui signifie que lorsque le modèle prédit la classe 1, il a raison 94% du temps. Pour la classe 0, la précision est de 0.83.
- **Rappel** : Pour la classe 1, le rappel est de 0.91, ce qui signifie que le modèle a identifié 91% des cas réels de la classe 1. Pour la classe 0, il a identifié 88% des cas réels.

- **F1-score** : C'est la moyenne harmonique de la précision et du rappel. Un F1-score élevé (0.92 pour la classe 1) indique un bon équilibre entre précision et rappel, montrant la fiabilité du modèle pour cette classe.
- **Support** : Indique le nombre d'occurrences réelles de chaque classe : 34 pour la classe 0 et 67 pour la classe 1.

2.3.2 Decision tree

```

Model: Decision Tree
Confusion Matrix:
[[22 12]
 [12 55]]
Classification Report:

```

	precision	recall	f1-score	support
0	0.65	0.65	0.65	34
1	0.82	0.82	0.82	67
accuracy			0.76	101
macro avg	0.73	0.73	0.73	101
weighted avg	0.76	0.76	0.76	101

```

Accuracy: 0.7623762376237624

```

La matrice de confusion, représentée par $\begin{bmatrix} 22 & 12 \\ 12 & 55 \end{bmatrix}$, est le fondement de cette évaluation. Elle se lit comme suit :

- **Vrais négatifs (TN)** : Le modèle a correctement prédit 22 cas négatifs.
 - **Faux positifs (FP)** : Le modèle a incorrectement prédit 12 cas positifs.
 - **Faux négatifs (FN)** : Le modèle a incorrectement prédit 12 cas négatifs.
 - **Vrais positifs (TP)** : Le modèle a correctement prédit 55 cas positifs.
- Voici un résumé de la classification :
- **Accuracy** : Avec un score global de 0.76, le modèle a bien prédit 76% des cas. Il a fait 76 prédictions justes sur 101 au total.
 - **Précision** : Pour la classe 1, la précision est de 0.82, ce qui signifie que lorsque le modèle prédit la classe 1, il a raison 82% du temps. Pour la classe 0, la précision est de 0.65.
 - **Rappel** : Pour la classe 1, le rappel est de 0.82, ce qui signifie que le modèle a identifié 82% des cas réels de la classe 1. Pour la classe 0, il a identifié 65% des cas réels.
 - **F1-score** : C'est la moyenne harmonique de la précision et du rappel. Un F1-score élevé (0.82 pour la classe 1) indique un bon équilibre entre précision et rappel, montrant la fiabilité du modèle pour cette classe.

- **Support** : Indique le nombre d'occurrences réelles de chaque classe : 34 pour la classe 0 et 67 pour la classe 1.

2.3.3 Random forest

```

Model: Random Forest
Confusion Matrix:
[[26  8]
 [ 5 62]]
Classification Report:

```

	precision	recall	f1-score	support
0	0.84	0.76	0.80	34
1	0.89	0.93	0.91	67
accuracy			0.87	101
macro avg	0.86	0.85	0.85	101
weighted avg	0.87	0.87	0.87	101

```

Accuracy: 0.8712871287128713

```

La matrice de confusion, représentée par $\begin{bmatrix} 26 & 8 \\ 5 & 62 \end{bmatrix}$, est le fondement de cette évaluation. Elle se lit comme suit :

- **Vrais négatifs (TN)** : Le modèle a correctement prédit 26 cas négatifs.
 - **Faux positifs (FP)** : Le modèle a incorrectement prédit 8 cas positifs.
 - **Faux négatifs (FN)** : Le modèle a incorrectement prédit 5 cas négatifs.
 - **Vrais positifs (TP)** : Le modèle a correctement prédit 62 cas positifs.
- Voici un résumé de la classification :
- **Accuracy** : Avec un score global de 0.87, le modèle a bien prédit 87% des cas. Il a fait 87 prédictions justes sur 101 au total.
 - **Précision** : Pour la classe 1, la précision est de 0.89, ce qui signifie que lorsque le modèle prédit la classe 1, il a raison 89% du temps. Pour la classe 0, la précision est de 0.84.
 - **Recall** : Pour la classe 1, le recall est de 0.93, ce qui signifie que le modèle a identifié 93% des cas réels de la classe 1. Pour la classe 0, il a identifié 76% des cas réels.
 - **F1-score** : C'est la moyenne harmonique de la précision et du rappel. Un F1-score élevé (0.91 pour la classe 1) indique un bon équilibre entre précision et rappel.
 - **Support** : Indique le nombre d'occurrences réelles de chaque classe : 34 pour la classe 0 et 67 pour la classe 1.

2.3.4 Logistic regression

```
Model: Logistic Regression
Confusion Matrix:
[[29  5]
 [ 8 59]]
Classification Report:
              precision    recall  f1-score   support

     0       0.78         0.85         0.82         34
     1       0.92         0.88         0.90         67

 accuracy          0.87         101
 macro avg         0.85         0.87         0.86         101
weighted avg         0.88         0.87         0.87         101

Accuracy: 0.8712871287128713
```

La matrice de confusion, représentée par $\begin{bmatrix} 29 & 5 \\ 8 & 59 \end{bmatrix}$, est le fondement de cette évaluation. Elle se lit comme suit :

- **Vrais négatifs (TN)** : Le modèle a correctement prédit 29 cas négatifs.
- **Faux positifs (FP)** : Le modèle a incorrectement prédit 5 cas positifs.
- **Faux négatifs (FN)** : Le modèle a incorrectement prédit 8 cas négatifs.
- **Vrais positifs (TP)** : Le modèle a correctement prédit 59 cas positifs.

Voici un résumé de la classification :

- **Accuracy** : Avec un score global de 0.87, le modèle a bien prédit 87% des cas. Il a fait 87 prédictions justes sur 101 au total.
- **Précision** : Pour la classe 1, la précision est de 0.92, ce qui signifie que lorsque le modèle prédit la classe 1, il a raison 92% du temps. Pour la classe 0, la précision est de 0.78.
- **Recall** : Pour la classe 1, le recall est de 0.88, ce qui signifie que le modèle a identifié 88% des cas réels de la classe 1. Pour la classe 0, il a identifié 85% des cas réels.
- **F1-score** : C'est la moyenne harmonique de la précision et du rappel. Un F1-score élevé (0.88 pour la classe 1) indique un bon équilibre entre précision et rappel

2.3.5 K nearest neighbors

```
Model: K-Nearest Neighbors
Confusion Matrix:
[[26  8]
 [ 3 64]]
Classification Report:
              precision    recall  f1-score   support

     0       0.90       0.76       0.83         34
     1       0.89       0.96       0.92         67

 accuracy          0.89         101
 macro avg         0.89         0.86         0.87         101
weighted avg         0.89         0.89         0.89         101

Accuracy: 0.8910891089108911
```

La matrice de confusion, représentée par $\begin{bmatrix} 26 & 8 \\ 3 & 64 \end{bmatrix}$, est le fondement de cette évaluation. Elle se lit comme suit :

- **Vrais négatifs (TN)** : Le modèle a correctement prédit 26 cas négatifs.
- **Faux positifs (FP)** : Le modèle a incorrectement prédit 8 cas positifs.
- **Faux négatifs (FN)** : Le modèle a incorrectement prédit 3 cas négatifs.
- **Vrais positifs (TP)** : Le modèle a correctement prédit 64 cas positifs.

Voici un résumé de la classification :

- **Accuracy** : Avec un score global de 0.89, le modèle a bien prédit 90% des cas. Il a fait 89 prédictions justes sur 101 au total.
- **Précision** : Pour la classe 1, la précision est de 0.89, ce qui signifie que lorsque le modèle prédit la classe 1, il a raison 89% du temps. Pour la classe 0, la précision est de 0.90.
- **Recall** : Pour la classe 1, le rappel est de 0.96, ce qui signifie que le modèle a identifié 96% des cas réels de la classe 1. Pour la classe 0, il a identifié 76% des cas réels.
- **F1-score** : C'est la moyenne harmonique de la précision et du rappel. Un F1-score élevé (0.92 pour la classe 1) indique un bon équilibre entre précision et rappel.
- **Support** : Indique le nombre d'occurrences réelles de chaque classe : 34 pour la classe 0 et 67 pour la classe 1.

2.4 Résultats obtenus

Voici un tableau qui résume les performances de chaque modèle :

Modèle	Accuracy	Précision	Recall	F1-score
SVC	0.90	0.94	0.91	0.92
Arbre de décision	0.76	0.82	0.82	0.82
Forêt aléatoire	0.87	0.89	0.93	0.91
Régression logistique	0.87	0.92	0.88	0.90
KNN	0.87	0.92	0.88	0.90

TABLE 2.1 – Comparaison des performances des différents modèles

2.5 Courbes d'apprentissage

Pour mieux comprendre le comportement des modèles, on a tracé des courbes d'apprentissage qui montrent comment les performances évoluent avec la quantité de données : Ici par exemple on peut voir que plus la taille des données sont importantes plus la performance sont faibles qui est une chose anormale.




FIGURE 2.1 – Courbe d'apprentissage pour SVC

Comme on peut le voir, le score d'entraînement est élevé au début et diminue légèrement à mesure que la taille de l'ensemble d'entraînement augmente. Cela s'explique par le fait que le modèle a plus de difficultés à mémoriser parfaitement toutes les données à mesure que leur quantité augmente. La courbe de validation montre la performance du modèle sur de nouvelles données, qu'il n'a pas vues pendant l'entraînement.




FIGURE 2.2 – Courbe d'apprentissage pour Random Forest

Ici, le score d'entraînement est de 1.0 (ou très proche) et reste constant, quelle que soit la taille de l'échantillon. Cela indique que le modèle a mémorisé parfaitement l'ensemble des données d'entraînement, ce qui est un signe de surapprentissage (overfitting). Le score de validation montre la performance du modèle sur des données nouvelles. Le score de validation se situe entre 0.82 et 0.86 et stagne ou diminue légèrement à mesure que l'échantillon d'entraînement augmente. L'écart important entre le score d'entraînement (1.0) et le score de validation (environ 0.85) confirme le problème de surapprentissage.




FIGURE 2.3 – Courbe d'apprentissage pour Arbre de décision

Le score d'entraînement est à 1.0 (100% d'exactitude) et reste parfait, quelle que soit la taille de l'échantillon. Cela signifie que le modèle a mémorisé parfaitement toutes les données d'entraînement. Le score de validation est beaucoup plus bas, oscillant autour de 0.75 à 0.80. Cet écart important entre la performance d'entraînement (parfaite) et la performance de validation (médiocre) confirme le surapprentissage.




FIGURE 2.4 – Courbe d'apprentissage pour Régression logistique

Au début, avec un petit échantillon de données, l'exactitude est élevée (plus de 0.90) car le modèle peut facilement mémoriser les exemples. Au fur et à mesure que l'ensemble d'entraînement grandit, le score d'entraînement diminue légèrement car le modèle a plus de difficulté à s'adapter parfaitement à toutes les données, ce qui est un comportement normal et sain. La courbe se stabilise autour de 0.85. Le score de validation augmente avec la taille de l'échantillon d'entraînement. C'est un signe positif, car cela signifie que plus le modèle voit de données, plus il apprend à généraliser correctement. Le score se stabilise autour de 0.84.




FIGURE 2.5 – Courbe d'apprentissage pour KNN

Le score d'entraînement augmente au début, puis se stabilise autour de 0.88-0.89. La courbe a tendance à s'améliorer puis à stagner avec plus de données d'entraînement. Le score de validation augmente avec la taille de l'échantillon d'entraînement, ce qui est une bonne chose car cela indique que le modèle apprend à mieux généraliser. Cependant, il se stabilise à un niveau relativement bas, autour de 0.82. Il y a un écart significatif et persistant entre les deux courbes, et elles ne se rejoignent pas. Cet écart suggère que le modèle est sous-ajusté (underfitting), même avec un grand nombre de données d'entraînement.

2.6 Analyse des résultats

En regardant les résultats, on peut faire plusieurs constats intéressants :

- Le modèle **SVC** donne les meilleurs résultats globaux avec un F1-score de 0.92
 - Les modèles **Random Forest** et **KNN** ont des performances assez similaires
 - L'**arbre de décision** semble sur-apprendre et a des scores plus bas
 - La **régression logistique** se comporte bien et arrive surtout à généraliser : au lieu de juste mémoriser les données, elle apprend vraiment les relations entre les variables
- Finalement, même si SVC avait les meilleurs scores, on a choisi la régression logistique pour la suite parce qu'elle est plus stable, c'est à dire moins sensible aux variations du jeu

de données et aux valeurs extrêmes, et plus facile à interpréter. C'est ce modèle qu'on a décidé de sauvegarder pour les prédictions futures.

Chapitre 3

Déploiement

Dans ce chapitre, nous présentons comment nous avons rendu notre modèle entraîné accessible et utilisable, en mettant en place une interface simple permettant de tester les prédictions.

3.1 Test interactif du modèle

Pour offrir une expérience utilisateur intuitive, nous avons développé un script Python qui invite l'utilisateur à saisir pas à pas les informations nécessaires.

Voici le fonctionnement :

- L'utilisateur renseigne ses notes académiques, à savoir : le **GRE Score**, le **TOEFL Score**, la **Note de l'université**, la force du **SOP** (Statement of Purpose) et du **LOR** (Letter of Recommendation), le **CGPA** (Grade Point Average cumulé), ainsi que son expérience en **recherche**.
- Si une information n'est pas disponible, une valeur par défaut est attribuée, afin de garantir le bon fonctionnement du modèle même avec des données manquantes.
- Une fois toutes les entrées collectées, le script affiche :
 - **Candidat admis** en cas de prédiction positive.
 - **Candidat non admis** dans le cas contraire.
 - De plus, grâce à la **régression linéaire**, le script affiche également le pourcentage estimé de chances d'admission du candidat. Ce pourcentage permet à l'utilisateur de mieux visualiser ses probabilités, même si la décision finale reste binaire selon un seuil prédéfini (ex : 0.69).

3.2 Chargement des modèles

Pour réutiliser les modèles entraînés sans les réentraîner, nous avons utilisé la bibliothèque **pickle**.

- Le modèle de **régression logistique** est sauvegardé dans `logistic.pkl` et permet de prédire la classe binaire (admis/non admis).
- Le modèle de **régression linéaire** est sauvegardé dans `linear.pkl` et permet d'estimer la probabilité d'admission en pourcentage.

Exemple de chargement :

```
import pickle as pkl
```

```
# Chargement du modèle logistique
with open('models/logistic.pkl', 'rb') as f:
    model_loaded = pickle.load(f)

# Chargement du modèle linéaire
with open('models/linear.pkl', 'rb') as f:
    linear_model = pickle.load(f)
```

3.3 Exemple d'utilisation

Une fois les modèles chargés, le script interagit avec l'utilisateur et réalise les prédictions :

```
# Appel de la fonction interactive pour la prédiction binaire
test_model_input(model_loaded)

# Estimation du pourcentage d'admission avec la régression linéaire
pred_prob = linear_model.predict(new_data)
print(f"Chances d'admission estimées : {pred_prob[0]*100:.2f}%")
```

Ce prototype constitue une première étape essentielle vers un déploiement à plus grande échelle, permettant à tout utilisateur de tester facilement ses chances d'admission.

Conclusion

Ce travail de recherche nous a permis d'aboutir à la création et à la validation d'un modèle prédictif dont l'objectif principal est d'évaluer les chances d'admission d'un étudiant, en s'appuyant sur le dataset. La méthodologie adoptée repose sur une succession d'étapes clés :

- **Prédiction en pourcentage** : Avant toute classification binaire, nous avons utilisé la **régression linéaire** pour estimer la probabilité d'admission d'un étudiant. Cette approche fournit une valeur continue interprétable entre 0 et 1, offrant une vision quantitative des chances d'admission. Elle permet ainsi de mieux guider l'utilisateur et de compléter les décisions binaires.
- **Préparation des données** : Cette phase préliminaire, souvent sous-estimée, s'est avérée déterminante. Elle a inclus le nettoyage des données, leur exploration approfondie, et la sélection des variables principales pour la prédiction.
- **Modélisation et classification** : Une comparaison approfondie parmi plusieurs algorithmes d'apprentissage supervisé a été réalisée. Nous avons confronté les performances du **SVC**, **Random Forest**, **Arbre de Décision**, **Régression Logistique** et **K Nearest Neighbors**, afin de déterminer lequel de ces algorithmes était le plus précis et adapté à notre problématique. La régression logistique, en particulier, a été utilisée pour produire la décision binaire (admis / non admis).
- **Évaluation** : Au-delà des métriques classiques de performance comme l'exactitude, la précision ou le score F1, nous avons analysé les courbes d'apprentissage pour détecter et comprendre les écueils classiques que sont le surajustement ou le sous-ajustement, garantissant ainsi la robustesse de notre modèle.
- **Déploiement** : Pour concrétiser cette étude, une application interactive a été développée. Elle permet à un utilisateur de saisir ses informations et d'obtenir non seulement la décision binaire grâce à la régression logistique, mais également une estimation du **pourcentage de chances d'admission** fournie par la régression linéaire. Cette double approche offre à l'utilisateur une vision plus complète et personnalisée.

L'examen méticuleux des performances a révélé que la **Régression Logistique** s'est imposée comme l'approche la plus pertinente pour notre jeu de données. Son excellence réside dans son équilibre et sa remarquable capacité à généraliser, évitant ainsi les pièges du surajustement dans lesquels certains concurrents sont tombés. Parallèlement, le modèle de **régression linéaire** a permis de quantifier les probabilités d'admission, donnant un indicateur continu et interprétable.

Enfin, ce mémoire ne se contente pas de présenter un modèle opérationnel ; il ouvre la voie à de multiples prolongements. Le développement d'une interface web intuitive ou la publication sous forme d'API constituent des évolutions naturelles pour étendre la portée de cet outil.

Cette recherche rappelle également que la performance d'un modèle de machine lear-

ning ne naît pas de la sophistication de l’algorithme, mais bien de la qualité du travail en amont : la préparation des données et leur analyse critique restent la pierre angulaire de tout projet réussi en science des données.

Table des matières

Introduction Générale	I
0.1 Contexte	I
0.2 Problématique	I
0.3 Objectifs	I
0.4 Démarche suivie	I
0.5 Structure du rapport	II
Remerciements	X
Résumé	XI
Abstract	XII
1 Exploration des données	1
1.1 Introduction	1
1.1.1 Chargement du jeu de données	1
1.1.2 Aperçu des données du dataset principale	1
1.1.3 Traitement des valeurs manquantes	2
1.1.4 Détection de doublons	2
1.1.5 Étude des valeurs aberrantes	2
1.1.6 Étude des corrélations	2
1.1.7 Conclusion de l'exploration	3
1.2 Présentation des dataset secondaires	3
1.3 Visualisation des données du dataset principale	7
1.4 Analyse univariée	7
1.4.1 GRE Score	7
1.4.2 CGPA	7
1.4.3 TOEFL Score	8
1.4.4 University Rating	9
1.4.5 Research	10
1.4.6 Chance of Admit	11
1.5 Analyse bivariée	12
1.5.1 GRE Score vs Chance of Admit	12
1.5.2 CGPA vs Chance of Admit	13
1.5.3 TOEFL Score vs Chance of Admit	14
1.5.4 Chance of Admit par expérience de recherche	15
1.5.5 Distribution du TOEFL selon University rating	16
1.5.6 Nombre de candidats selon l'expérience de recherche	17
1.6 Conclusion de l'exploration	18

2	Modélisation	19
2.1	Prédiction en pourcentage avec Régression linéaire	19
2.2	Autres modèles de classification	19
2.3	Évaluation des modèles	20
2.3.1	SVC	20
2.3.2	Decision tree	21
2.3.3	Random forest	22
2.3.4	Logistic regression	23
2.3.5	K nearest neighbors	24
2.4	Résultats obtenus	24
2.5	Courbes d'apprentissage	25
2.6	Analyse des résultats	28
3	Déploiement	30
3.1	Test interactif du modèle	30
3.2	Chargement des modèles	30
3.3	Exemple d'utilisation	31
	Conclusion	32
	Glossaire	36
	Annexes	38
	Bibliographie	48

Glossaire

Dans cette section, nous allons définir tous les termes techniques et acronymes utilisés dans notre rapport.

- **accuracy** : la proportion de prédictions correctes parmi le nombre total de prédictions.
- **Arbre de décision** : un modèle prédictif qui utilise une structure arborescente pour représenter les décisions et leurs conséquences.
- **bivariée** : une analyse qui examine la relation entre deux variables.
- **classification** : une technique d'analyse de données qui prédit la catégorie ou la classe à laquelle appartient une observation donnée.
- **courbe d'apprentissage** : un graphique qui montre comment les performances d'un modèle évoluent avec la quantité de données d'entraînement.
- **Decision tree** : un algorithme d'apprentissage automatique qui utilise une multitude d'arbres de décision pour améliorer la précision de la classification ou de la régression.
- **dataset** : un ensemble structuré de données, souvent présenté sous forme de tableau.
- **feature** : une caractéristique ou une variable utilisée comme entrée dans un modèle d'apprentissage automatique.
- **F1-score** : la moyenne harmonique entre la précision et le recall.
- **KNN** : K Nearest Neighbors, un algorithme de classification qui classe une observation en fonction des classes de ses K voisins les plus proches dans l'espace de caractéristiques.
- **Kaggle** : une plateforme en ligne pour les compétitions de science des données et le partage de datasets.
- **hyperplan** : une frontière de décision qui sépare les différentes classes dans un espace de caractéristiques.
- **modèle** : une représentation mathématique ou algorithmique utilisée pour faire des prédictions ou des classifications basées sur des données.
- **numpy** : une bibliothèque Python utilisée pour le calcul scientifique et le traitement de tableaux multidimensionnels.
- **pandas** : une bibliothèque Python utilisée pour la manipulation et l'analyse de données.
- **precision** : la proportion de vrais positifs parmi les prédictions positives.
- **régression linéaire** : une technique d'analyse de données qui prédit la valeur de données inconnues en utilisant une autre valeur de données apparentée et connue.
- **régression logistique** : une technique de classification qui utilise une fonction logistique pour modéliser la probabilité qu'une observation appartienne à une classe particulière.
- **recall** : la proportion de vrais positifs parmi les observations réelles positives.
- **SVC** : Support Vector Classifier, un algorithme de classification qui trouve l'hyperplan optimal pour séparer les différentes classes dans un espace de caractéristiques.
- **scikit-learn** : une bibliothèque Python pour l'apprentissage automatique.

- **score entraînement** : une mesure de la performance d'un modèle sur l'ensemble de données d'entraînement.
- **score validation** : une mesure de la performance d'un modèle sur un ensemble de données de test.
- **seaborn** : une bibliothèque Python basée sur matplotlib qui fournit une interface de haut niveau pour dessiner des graphiques statistiques attrayants et informatifs.
- **StandardScaler** : une technique de normalisation des données qui transforme les caractéristiques pour qu'elles aient une moyenne de 0 et un écart-type de 1.
- **surapprentissage** : un phénomène où un modèle apprend trop bien les détails et le bruit des données d'entraînement, ce qui nuit à sa capacité à généraliser à de nouvelles données.
- **train-test split** : la division d'un ensemble de données en un ensemble d'entraînement et un ensemble de test pour évaluer les performances d'un modèle.
- **univariée** : une analyse qui examine une seule variable à la fois.
- **variable cible** : la variable que l'on cherche à prédire ou à expliquer dans une analyse de données.
- **variable discrète** : une variable qui peut prendre un nombre fini ou dénombrable de valeurs.
- **variable quantitative** : une variable qui peut être mesurée numériquement.
- **visualisation** : l'utilisation de graphiques pour représenter les données.
- **web scraping / scraper** : le processus d'extraction de données à partir de sites web.
- **matplotlib** : une bibliothèque Python utilisée pour la création de visualisations statiques, animées et interactives.

Annexes

Bibliothèques utilisées pour l'EDA

```
import pandas as pd
import matplotlib.pyplot as plt
import numpy as np
import seaborn as sns
```

Explication : pandas pour la manipulation des données, matplotlib et seaborn pour la visualisation graphique, numpy pour les calculs numériques.

Chargement du dataset

```
df = pd.read_csv('data/Admission_Predict_v2.csv')
```

Explication : La fonction `pd.read_csv()` permet de charger le dataset afin de l'exploiter pour l'analyse et la modélisation.

Affichage des premières lignes du dataset

```
df.head()
```

	Serial No.	GRE Score	TOEFL Score	University Rating	SOP	LOR	CGPA	Research	Chance of Admit	LOR
0	1	337.0	118.0	4	4.5	4.5	9.65	1	0.92	NaN
1	2	324.0	107.0	4	4.0	4.5	8.87	1	0.76	NaN
2	3	316.0	104.0	3	3.0	3.5	8.00	1	0.72	NaN
3	4	322.0	110.0	3	3.5	2.5	8.67	1	0.80	NaN
4	5	314.0	103.0	2	2.0	3.0	8.21	0	0.65	NaN

Explication : La méthode `df.head()` affiche les cinq premières lignes du dataset pour un aperçu rapide de sa structure.

Aperçu du type des données

```
df.info()
#GRE : Signifie Graduate Record Examination
#TOEFL : Signifie Test of English as a Foreign Language
#SOP : Signifie Statement of Purpose
#utilisé par les comités d'admission pour évaluer les objectifs académiques
#LOR : Signifie Letter of Recommendation
#utilisée pour juger du sérieux, du potentiel et des qualités personnelles du candidat
#CGPA : Signifie Cumulative Grade Point Average
#utilisé pour évaluer la performance académique globale
#Research : Signifie Expérience de recherche cad activité extra-scolaire

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 550 entries, 0 to 549
Data columns (total 10 columns):
#   Column          Non-Null Count  Dtype
---  -
0   Serial No.      550 non-null   int64
1   GRE Score       550 non-null   float64
2   TOEFL Score     513 non-null   float64
3   University Rating 550 non-null   int64
4   SOP            513 non-null   float64
5   LOR            550 non-null   float64
6   CGPA           550 non-null   float64
7   Research        550 non-null   int64
8   Chance of Admit 550 non-null   float64
9   LOR            0 non-null     float64
dtypes: float64(7), int64(3)
memory usage: 43.1 KB
```

Explication : `df.info()` fournit un résumé des types de données et du nombre de valeurs non nulles par colonne.

Résumé statistique du dataset

```
df.describe()
```

	Serial No.	GRE Score	TOEFL Score	University Rating	SOP	LOR	CGPA	Research	Chance of Admit	LOR
count	550.000000	550.000000	513.000000	550.000000	513.000000	550.000000	550.000000	550.000000	550.000000	0.0
mean	250.896364	316.335651	107.204041	3.125455	3.376218	3.484545	8.591772	0.572727	0.721655	NaN
std	146.927197	12.674963	6.434952	1.135889	0.995978	0.925375	0.616908	0.495133	0.142310	NaN
min	1.000000	277.754368	91.916154	1.000000	1.000000	1.000000	6.800000	0.000000	0.340000	NaN
25%	121.250000	308.000000	102.725335	2.000000	2.500000	3.000000	8.131200	0.000000	0.630000	NaN
50%	251.500000	316.000000	107.000000	3.000000	3.500000	3.500000	8.589128	1.000000	0.720000	NaN
75%	378.750000	325.000000	112.000000	4.000000	4.000000	4.000000	9.060000	1.000000	0.830000	NaN
max	500.000000	353.144823	125.588646	5.000000	5.000000	5.000000	10.240747	1.000000	0.970000	NaN

Explication : `df.describe()` calcule des statistiques descriptives : moyenne, écart-type, valeurs minimales et maximales.

Suppression des colonnes inutiles

```
df_clean = df.drop(columns=[df.columns[9] , df.columns[0]])
```

Explication : La colonne `Serial No.` et le doublon `LOR` ont été supprimés car non pertinents pour l'analyse.

Nettoyage des données

```
df_clean.isna().sum()
```

GRE Score	0
TOEFL Score	37
University Rating	0
SOP	37
LOR	0
CGPA	0
Research	0
Chance of Admit	0
dtype:	int64

```
df_clean = df_clean.dropna()
```

Explication : `df_clean.isna().sum()` permet de compter les valeurs manquantes. Elles ont ensuite été supprimées avec `df_clean.dropna()`.

Visualisation univariée des données

```
df_clean["GRE Score"].hist()
```

```
df_clean["CGPA"].hist()
```

```
df_clean["TOEFL Score"].hist()
```

```
df_clean["University Rating"].hist()
```

```
df_clean["Chance of Admit "].hist()
```

```
df_clean["Research"].value_counts().plot(kind='pie', autopct='%1.1f%%')
```

Explication : Ces codes présentent la distribution de chaque variable individuelle.

Visualisation bivariée des données

```
df_clean.plot.scatter(x='GRE Score', y='Chance of Admit ', colormap='viridis', alpha=0.5)
```

```
df_clean["GRE Score"].corr(df_clean["Chance of Admit "])
```

```
df_clean.plot.scatter(x='CGPA', y='Chance of Admit ', colormap='viridis', alpha=0.6)
```

```
df_clean["CGPA"].corr(df_clean["Chance of Admit "])
```

```
df_clean.plot.scatter(x='TOEFL Score', y='Chance of Admit ', colormap='viridis', alpha=0.5)
```

```
df_clean["TOEFL Score"].corr(df_clean["Chance of Admit "])
```

```
df_clean.boxplot(column='Chance of Admit ', by='Research', figsize=(10, 6))
```

```
df_clean["Research"].corr(df_clean["Chance of Admit "])
```

```
corr_matrix = df_clean.corr(numeric_only=True)
corr_matrix
```

```
# Visualiser la corrélation entre la moyenne générale (CGPA) et la chance d'admission.
plt.scatter(df_clean['CGPA'], df_clean['Admitted'], alpha=0.6, color='green')
plt.title("CGPA vs Admission")
plt.xlabel("CGPA")
plt.ylabel("Admit")
plt.show()
```

```
sns.boxplot(x='University Rating', y='TOEFL Score', data=df_clean)
plt.title("Distribution TOEFL selon University Rating")
plt.show()
```

```
sns.pairplot(df_clean[['GRE Score', 'TOEFL Score', 'CGPA', 'Admitted']].dropna())
plt.suptitle("Relations entre variables clés", y=1.02)
plt.show()
```

Explication : Ces codes montrent les relations entre deux variables, utiles pour détecter corrélations et tendances.

Variables utilisées pour l'entraînement du modèle (régression)

```
features = ['GRE Score', 'TOEFL Score', 'University Rating', 'SOP', 'LOR ', 'CGPA', 'Research']
X_reg = df_clean[features]
y_reg = df_clean['Chance of Admit ']
```

Variables utilisées pour l'entraînement du modèle (classification)

```
• #Les colonnes qu'on utilisera pour entrainer le modèle
features = ['GRE Score', 'TOEFL Score', 'University Rating', 'SOP', 'LOR ', 'CGPA', 'Research']
X = df_clean[features]
y = df_clean['Admitted']
```

Bibliothèques utilisées pour l'entraînement du modèle

```
# Importation des bibliothèques nécessaires pour le modèle
from sklearn.svm import SVC
from sklearn.tree import DecisionTreeClassifier
from sklearn.ensemble import RandomForestClassifier
from sklearn.linear_model import LogisticRegression
from sklearn.neighbors import KNeighborsClassifier
from sklearn.preprocessing import StandardScaler
from sklearn.model_selection import train_test_split, learning_curve, cross_val_score
from sklearn.metrics import classification_report, confusion_matrix, accuracy_score
from sklearn.pipeline import Pipeline
from sklearn.linear_model import LinearRegression
from sklearn.preprocessing import StandardScaler
```

Imports principaux :

- `from sklearn.svm import SVC` : Support Vector Classifier.
- `from sklearn.tree import DecisionTreeClassifier` : Arbre de décision.
- `from sklearn.ensemble import RandomForestClassifier` : Forêt aléatoire. s
- `from sklearn.linear_model import LogisticRegression, LinearRegression` : Régression logistique et
- `from sklearn.neighbors import KNeighborsClassifier` : K plus proches voisins.
- `from sklearn.preprocessing import StandardScaler` : Normalisation des données.
- `from sklearn.model_selection import train_test_split, learning_curve, cross_val_score` : Division des données en set de validation croisée.
- `from sklearn.metrics import classification_report, confusion_matrix, accuracy_score` : Métriques d'évaluation.
- `from sklearn.pipeline import Pipeline` : Chaîne de traitement complète. s

Exemple de code utilisé pour l'entraînement du modèle

```
# Pipeline
rfc_pipeline = Pipeline([
    ('scaler', StandardScaler()),
    ('classifier', RandomForestClassifier(random_state=42))
])

# Courbe d'apprentissage
train_sizes, train_scores, val_scores = learning_curve(
    rfc_pipeline,
    X, y,
    train_sizes=np.linspace(0.1, 1.0, 10),
    cv=5,
    scoring='accuracy',
    shuffle=True,
    random_state=42
)

# Moyennes et écarts-types
train_mean = np.mean(train_scores, axis=1)
val_mean = np.mean(val_scores, axis=1)
train_std = np.std(train_scores, axis=1)
val_std = np.std(val_scores, axis=1)

# Affichage 1 : simple
plt.figure(figsize=(10, 5))
plt.plot(train_sizes, train_mean, 'o-', Label="Train Accuracy")
plt.plot(train_sizes, val_mean, 'o-', Label="Validation Accuracy")
plt.title("Learning Curve")
plt.xlabel("Nombre d'échantillons d'entraînement")
plt.ylabel("Accuracy")
plt.legend()
plt.grid(True)
plt.show()

# Affichage 2 : avec bandes d'incertitude
plt.figure(figsize=(10, 6))
plt.plot(train_sizes, train_mean, 'o-', color='blue', Label='Score entraînement')
plt.fill_between(train_sizes, train_mean - train_std, train_mean + train_std, alpha=0.1, color='blue')

plt.plot(train_sizes, val_mean, 'o-', color='green', Label='Score validation')
plt.fill_between(train_sizes, val_mean - val_std, val_mean + val_std, alpha=0.1, color='green')

plt.title('Courbe d'apprentissage')
plt.xlabel('Taille de l\'échantillon d\'entraînement')
plt.ylabel('Exactitude')
plt.legend(loc='best')
plt.grid(True)
plt.tight_layout()
plt.show()
```

Exemple de code utilisé pour tester le modèle

```
def test_model_input(model):
    print("=== Prédiction d'admission à l'université ===")
    print("Tape 'aucun' si tu n'as jamais passé un test ou fourni un document.\n")

    # GRE Score
    while True:
        gre_input = input("GRE Score (260-340 ou 'aucun') : ").strip().lower()
        if gre_input == 'aucun':
            gre = 300 # valeur par défaut neutre
            print("GRE non fourni. Valeur par défaut utilisée : 300")
            break
        try:
            gre = float(gre_input)
            if 260 <= gre <= 340:
                break
            else:
                print("Valeur hors plage.")
        except ValueError:
            print("Entrée invalide.")

    # TOEFL Score
    while True:
        toefl_input = input("TOEFL Score (0-120 ou 'aucun') : ").strip().lower()
        if toefl_input == 'aucun':
            toefl = 90 # valeur par défaut neutre
            print("TOEFL non fourni. Valeur par défaut utilisée : 90")
            break
        try:
            toefl = float(toefl_input)
            if 0 < toefl <= 120:
                break
            else:
                print("Valeur hors plage.")
        except ValueError:
            print("Entrée invalide.")

    # University Rating
    while True:
        ur_input = input("Note de l'université (1 à 5 ou 'aucun') : ").strip().lower()
        if ur_input == 'aucun':
            ur = 3 # neutre
            print("Note d'université non fournie. Valeur par défaut utilisée : 3")
            break
        try:
            ur = int(ur_input)
            if 1 <= ur <= 5:
                break
            else:
                print("Valeur hors plage.")
        except ValueError:
            print("Entrée invalide.")

    # SOP
    while True:
        sop_input = input("SOP (Lettre de motivation notée de 0.0 à 5.0 ou 'aucun') : ").strip().lower()
        if sop_input == 'aucun':
```

```
    # GRE Score
    while True:
        gre_input = input("GRE Score (260-340 ou 'aucun') : ").strip().lower()
        if gre_input == 'aucun':
            gre = 300 # valeur par défaut neutre
            print("GRE non fourni. Valeur par défaut utilisée : 300")
            break
        try:
            gre = float(gre_input)
            if 260 <= gre <= 340:
                break
            else:
                print("Valeur hors plage.")
        except ValueError:
            print("Entrée invalide.")

    # TOEFL Score
    while True:
        toefl_input = input("TOEFL Score (0-120 ou 'aucun') : ").strip().lower()
        if toefl_input == 'aucun':
            toefl = 90 # valeur par défaut neutre
            print("TOEFL non fourni. Valeur par défaut utilisée : 90")
            break
        try:
            toefl = float(toefl_input)
            if 0 < toefl <= 120:
                break
            else:
                print("Valeur hors plage.")
```

Explication : Ces extraits montrent l'évaluation du modèle sur le dataset de test, incluant la prédiction et l'analyse des performances.

Bibliographie

- **Dataset principal** : *admission_rate_ver_1.csv*.
Disponible sur : <https://dr-raz.org/statistical-literacy-csv-data>.
Consulté le 25 août 2025.
- **Dataset test** : *gc_data.csv*.
Disponible sur : http://sourceforge.net/projects/triangleinequal/files/Grad%20Cafe%20Data/gc_data.csv/download.
Consulté le 20 août 2025.
- **Dataset test** : *Predict students dropout and academic success*.
Disponible sur : <https://archive.ics.uci.edu/dataset/697/predict+students+dropout+and+academic+success>.
Consulté le 18 août 2025.
- **Dataset test** : *Graduate school admission data*.
Disponible sur : https://figshare.com/articles/dataset/Graduate_school_admission_data/19561582.
Consulté le 22 août 2025.
- **TheGradCafe** : *How to scrape the website of thegradcafe*.
Disponible sur : <https://forum.thegradcafe.com/topic/51483-scraped-admissions-data>.
Consulté le 21 août 2025.
- **Régression linéaire**. Disponible sur : https://fr.wikipedia.org/wiki/R%C3%A9gression_lin%C3%A9aire. Consulté le 1 septembre 2025.
- **Classification**. Disponible sur : [https://fr.wikipedia.org/wiki/Classification_\(statistiques\)](https://fr.wikipedia.org/wiki/Classification_(statistiques)). Consulté le 1 septembre 2025.
- **Régression logistique**. Disponible sur : https://fr.wikipedia.org/wiki/R%C3%A9gression_logistique. Consulté le 1 septembre 2025.
- **Arbre de décision (Decision Tree)**. Disponible sur : https://fr.wikipedia.org/wiki/Arbre_de_d%C3%A9cision. Consulté le 1 septembre 2025.
- **Support Vector Machine (SVC)**. Disponible sur : https://fr.wikipedia.org/wiki/Machine_%C3%A0_vecteurs_de_support. Consulté le 1 septembre 2025.
- **Hyperplan**. Disponible sur : <https://fr.wikipedia.org/wiki/Hyperplan>. Consulté le 1 septembre 2025.
- **KNN (K Nearest Neighbors)**. Disponible sur : https://fr.wikipedia.org/wiki/M%C3%A9thode_des_k_plus_proches_voisins. Consulté le 1 septembre 2025.
- **Valeurs manquantes**. Disponible sur : https://fr.wikipedia.org/wiki/Imputation_en_statistique. Consulté le 1 septembre 2025.
- **Validation croisée (Score validation)**. Disponible sur : [https://fr.wikipedia.org/wiki/Validation_crois%C3%A9e_\(statistiques\)](https://fr.wikipedia.org/wiki/Validation_crois%C3%A9e_(statistiques)). Consulté le 1 septembre 2025.
- **Variable quantitative**. Disponible sur : https://fr.wikipedia.org/wiki/Variable_al%C3%A9atoire. Consulté le 1 septembre 2025.
- **Variable discrète**. Disponible sur : https://fr.wikipedia.org/wiki/Variable_

- al%C3%A9atoire#Variables_discr%C3%A8tes. Consulté le 1 septembre 2025.
- **Variable cible.** Disponible sur : https://fr.wikipedia.org/wiki/Variable_d%C3%A9pendante. Consulté le 1 septembre 2025.
 - **Web scraping (Scraper).** Disponible sur : https://fr.wikipedia.org/wiki/Web_scraping. Consulté le 1 septembre 2025.
 - **Courbe d'apprentissage.** Disponible sur : https://en.wikipedia.org/wiki/Learning_curve. Consulté le 1 septembre 2025.
 - **Modèle prédictif.** Disponible sur : https://fr.wikipedia.org/wiki/Mod%C3%A8le_pr%C3%A9dictif. Consulté le 1 septembre 2025.
 - **Surapprentissage.** Disponible sur : <https://fr.wikipedia.org/wiki/Surapprentissage>. Consulté le 1 septembre 2025.
 - **Pandas.** Disponible sur : [https://fr.wikipedia.org/wiki/Pandas_\(logiciel\)](https://fr.wikipedia.org/wiki/Pandas_(logiciel)). Consulté le 1 septembre 2025.
 - **Matplotlib.** Disponible sur : <https://fr.wikipedia.org/wiki/Matplotlib>. Consulté le 1 septembre 2025.
 - **Seaborn.** Disponible sur : <https://seaborn.pydata.org/>. Consulté le 1 septembre 2025.
 - **NumPy.** Disponible sur : <https://fr.wikipedia.org/wiki/NumPy>. Consulté le 1 septembre 2025.
 - **Scikit-learn.** Disponible sur : <https://fr.wikipedia.org/wiki/Scikit-learn>. Consulté le 1 septembre 2025.
 - **StandardScaler.** Disponible sur : <https://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.StandardScaler.html>. Consulté le 1 septembre 2025.
 - **Train-test split.** Disponible sur : https://scikit-learn.org/stable/modules/cross_validation.html#cross-validation. Consulté le 1 septembre 2025.
 - **Accuracy.** Disponible sur : https://fr.wikipedia.org/wiki/Pr%C3%A9cision_et_rappel. Consulté le 1 septembre 2025.
 - **Precision.** Disponible sur : https://fr.wikipedia.org/wiki/Pr%C3%A9cision_et_rappel. Consulté le 1 septembre 2025.
 - **Recall.** Disponible sur : https://fr.wikipedia.org/wiki/Pr%C3%A9cision_et_rappel. Consulté le 1 septembre 2025.
 - **F1-score.** Disponible sur : <https://fr.wikipedia.org/wiki/F-mesure>. Consulté le 1 septembre 2025.
 - **Kaggle.** Disponible sur : <https://fr.wikipedia.org/wiki/Kaggle>. Consulté le 1 septembre 2025.